

共享电单车电池换电路径优化： 从流体库存动力学到时空图网络流

李明霄
清华大学工业工程系

2026 年 7 月 29 日

符号表

本文按功能模块汇总全部数学符号。仅在特定上下文中引入的符号归入对应模块；全局使用的符号置于首个相关模块中。

1. 系统基本元素：集合、grid与基础参数

- t, τ — 连续时间变量。
- T — 单次换电路由规划的周期长度。
- i, j — grid（节点）索引；0 表示充电柜。
- $\mathcal{J}$ — 所有grid的集合； $\mathcal{N} = \mathcal{J} \cup \{0\}$ 。
- $\delta^+(j) = \{(j, k) : k \in \mathcal{J}, k \neq j\}$, $\delta^-(j) = \{(k, j) : k \in \mathcal{J}, k \neq j\}$ — grid j 的出弧/入弧集合。
- a_{ij} — 从grid i 到 j 的行驶时间（基于Haversine球面距离，恒定速度 30 km/h）。
- C — 服务车单次巡回的电池携带容量。
- c — 单块电池的换电服务时间。
- λ_j — grid j 的用户出发（需求）率（Poisson过程，单位时间）； λ ：区域级总体需求率。
- ρ_j — grid j 的车辆到达（归还）率（Poisson过程，单位时间）； ρ ：区域级总体归还率。
- $n_{j,k}$ — $t = 0$ 时刻grid j 中处于电池状态 k 的车辆初始数量。
- $N_{j,0} = \sum_{k=1}^2 n_{j,k}$ — grid j 的初始可服务库存（即将耗尽 + 正常）。

2. 电池状态

- $\mathcal{K} = \{\text{low}, \text{soon}, \text{normal}\}$ — 离散电池状态类别：低电量（ $< 20\%$ ，不可用）、即将耗尽（ $20\% \sim 50\%$ ， 80% 服务权重）、正常（ $> 50\%$ ，全额服务）。
- $k \in \mathcal{K}$ 或 $k = 1, 2, 3$ — 状态索引。在流体ODEs中仅追踪 $k = 1, 2$ （即将耗尽、正常）；低电量状态被视为仅在换电时刻可转化的静态库存池。

3. 全局与局部状态分布

- Θ_k^{global} — 全局（区域级）处于状态 k 的车辆比例，用于近似任意grid到达车辆的组成（假设2）。
- $\Theta_{j,k}^{\text{grid}}(t) = N_{j,k}(t)/N_j(t)$ — t 时刻grid j 中状态 k 的局部比例，其中 $N_j(t) = \sum_{k=1}^2 N_{j,k}(t)$ 。

4. 库存动力学（流体ODE系统）

- $N_{j,k}(t)$ — t 时刻grid j 中处于状态 k 的车辆数量（连续流体近似）。
- $N_j(t) = \sum_{k=1}^2 N_{j,k}(t)$ — grid j 的可服务库存。
- $N_k(t) = \sum_j N_{j,k}(t)$ — 全区域状态 k 的可服务车辆总量。
- $N(t) = \sum_{k=1}^2 N_k(t)$ — 全区域可服务库存总量（即将耗尽 + 正常）。
- $N_{\text{serv},j}(t) = N_{j,\text{soon}}(t) + N_{j,\text{normal}}(t)$ — grid j 的可服务车辆数（等价于 $N_j(t)$ ）。
- $N_{\text{in}}(t) \sim \text{Poisson}(\rho_j t)$, $N_{\text{out}}(t) \sim \text{Poisson}(\lambda_j t)$ — 区间 $[0, t]$ 上的累积到达/离开计数（流体极限中使用期望值）。

5. 效用评估：缺货、服务价值与换电机制

- t_0 — 自然动态下的缺货时刻，由 $N_{\text{serv},j}(t_0) = 0$ 定义。
- $\tilde{t}_0$ — 换电干预后的缺货时刻。
- $\tau_0 = \min(t_0, T)$, $\tilde{\tau}_0 = \min(\tilde{t}_0, T)$ — 换电前后的有效服务上界。
- $S_j(u_j)$ — 从到达时刻 u_j 至 τ_0 收集的基线净服务价值，衡量质量加权的净流出服务。
- $\tilde{S}_j(u_j, y_j)$ — 换电后的服务价值，覆盖从 u_j 至 $\tilde{\tau}_0$ ，换电量为 y_j 。
- $U_j(u_j, y_j) = \tilde{S}_j - S_j$ — 换电操作的边际效用（路径优化的最大化目标）。
- $\tilde{N}_{j,0} = N_j(u) + \min\{y_j, N_{j,\text{low}}(u)\}$ — 换电后的总可服务库存。
- $\tilde{n}_{j,k}$ — 换电瞬间状态 k 的存量（分段函数，依赖于 y_j 、 $N_{j,\text{low}}$ 、 $N_{j,\text{soon}}$ ；见式(4.7)）。

- $\tilde{N}_{j,k}(t)$ — 换电后库存轨迹 ($t > u$)，遵循相同ODE形式，初始条件替换为 $\tilde{n}_{j,k}$ ，时间原点平移至 u 。
- $\tilde{\Theta}_{j,k}^{\text{grid}}(t) = \tilde{N}_{j,k}(t)/\tilde{N}_j(t)$ — 换电后的状态比例。
- $\Delta_{\text{swap}} = \min\{y_j, N_{j,\text{low}}\} + 0.2 \max\{0, y_j - N_{j,\text{low}}\}$ — 换电瞬间注入的净服务质量增量（闭式解；优先换低电量，其次换即将耗尽，即将耗尽仅有 20% 边际增益）。

6. 路径优化：经典VRP决策变量

- $x_{ij} \in \{0, 1\}$ — 二元路由弧变量：1 表示车辆直接从 i 驶向 j 。
- $v_j \in \{0, 1\}$ — 访问指示变量：1 表示grid j 被服务。
- $y_j \in \mathbb{Z}^+$ — grid j 的换电数量。
- $u_j \geq 0$ — 车辆到达grid j 的时间（MTZ时序追踪变量）。
- M — MTZ约束中的Big-M常数（充分大，例如 $M = T + \max_{i,j} a_{ij} + c \cdot C$ ）。

7. 效用张量与离散化（MIP接口）

- P — 时间离散段数； $\mathcal{S} = \{0, 1, \dots, P\}$ 为断点索引集合。
- τ_s — 离散断点 $s \in \mathcal{S}$ 对应的物理时刻，满足 $\tau_0 = 0$ ， $\tau_P = T$ 。
- $\mathcal{Y} = \{0, 1, \dots, C\}$ — 可行换电量集合。
- $\Omega_j(y, \tau_s)$ — 预计算效用张量：在时刻 τ_s 到达grid j 并换电 y 块的边际效用，通过第4节的闭式 U_j 离线计算得到。
- $\lambda_{j,y,s}$ — SOS2插值权重变量，将连续到达时间映射至离散断点（仅方案A使用；STGraph中已消除）。
- $\delta_1 \geq \delta_2 \geq \dots \geq \delta_P$ — 二元delta阶梯变量，用于到达时间编码（方案B；STGraph中已消除）。
- $f_{ij} \leq C \cdot x_{ij}$ — 弧 (i, j) 上的单商品流，用于加强LP耦合（方案B；STGraph中已消除）。

8. 时空图（STGraph）

- $\mathcal{T} = \{0, 1, \dots, P\}$ — 离散时间步索引集合（与 $\mathcal{S}$ 同义；侧重于DAG拓扑时使用）。
- (i, s) — 时空节点：车辆在时刻 τ_s 位于物理节点 i 。
- $e = (i^e, s_1^e, j^e, s_2^e, y^e)$ — 时空弧五元组：在 τ_{s_1} 从 i 出发，换电 y^e 块，在 τ_{s_2} 到达 j 。
- $\mathcal{E}$ — 所有可行时空弧的集合（通过右取整和KNN过滤离线枚举生成）。

- $x_e \in \{0, 1\}$ — 弧 $e \in \mathcal{E}$ 的二元激活变量。
- $\delta_{ST}^+(j, s), \delta_{ST}^-(j, s)$ — 时空节点 (j, s) 的出弧/入弧集合。
- K — KNN稀疏化后每个节点保留的最近空间邻居数（默认 $K = 50$ ）。

9. 运算符

- $[x]_+ = \max(0, x)$ — 正部运算符。
- $(\cdot)'$ 或 $\frac{d(\cdot)}{dt}$ — 时间导数。

1 引言

共享微出行已经历了十年的变革性增长。仅在美国和加拿大，共享单车和滑板车在2023年就完成了1.57亿次出行——超越了2019年1.47亿次的前疫情峰值，使2010年以来的累计出行总量达到8.87亿次 [20]。电动自行车（电单车）是这一扩张的主要引擎：站点式电单车出行量同比增长40%，电单车目前已占美国所有站点式共享单车出行的近半数，而全球共享单车市场预计在未来十年将维持两位数的年增长率 [20, 13]。这一发展轨迹反映了城市出行方式的结构性转变——从私家车拥有转向按需、低碳的替代方案 [1, 26]。

然而，支撑电单车共享系统可持续运营的核心环节——电池换电——引入了一个在决策复杂性上远超传统单车调配问题的优化难题。在传统单车共享系统中，唯一需要调配的空间资源是单车本身：再平衡意味着将单车从过剩站点搬运至短缺站点 [24]。而在电单车系统中，每辆车还携带着第二种随时间衰减的资源：其电池电量。随着用户骑行，可用电量的空间分布持续退化，形成局部“电池荒漠”——停放的车辆因电量不足而无法服务到达的需求。为对冲这一衰减，运营商派遣服务车辆在各grid间行驶，对亏电电池进行物理更换。由此产生的运营决策——访问哪些grid、以何种顺序、在什么时刻到达、每次停留更换多少电池——构成了一个时间依赖、容量受限的路径规划问题。关键在于：任意一次换电操作的价值并非固定的输入参数，而是电池库存演化这一随机排队过程所涌现出的内在属性 [33]。

这一问题恰好落在一个两股成熟研究传统相互错位的交叉地带。机器学习社区持续产出日益精准的时空需求预测模型；运筹学社区则提供了强大的组合优化引擎，但其前提是目标函数系数固定且已知。两者之间缺失了一个关键的接口：一种数学上严格的方式，将随机系统状态预测转换为优化器可用的目标函数值。Predict-then-Optimize (PtO) 范式 [5, 9] 将这一接口作为一个研究议程正式提出，但将其落地于电池换电路径规划，需要一个具体的机制——一个效用函数，它消化排队动力学的流体近似，输出良定义的目标系数，同时忠实地保留了使问题本质困难的时间结构。设计并验证这一机制，是本文的中心任务。

我们的框架立足于三项贡献。 **第一**，我们建立了多grid电单车库存系统的连续时间流体近似模型。通过将电池电量离散化为三种运营状态（低电量、即将耗尽、正常），我们获得了一个常微分方程（ODE）系统，其在换电后的库存演化上存在闭式解析解。该建模方式从根本上消除了离散状态马尔可夫链固有的维度灾难，同时保留了用户到达、离开和电池状态混合这一随机过程的本质特征。 **第二**，我们利用了ODE系统的一个结构性特征——净服务价值积分可退化为质量加权库存的边界求值——导出了一个常数时间复杂度的封闭效用函数 $U_j(u_j, y_j)$ ，用于量化在时刻 u_j 到达grid j 并更换 y_j 块电池的边际收益。该函数充当了下游路径优化的目标系数生成器，弥合了连续时间随机建模与离散组合优化之间的鸿沟。 **第三**，我们将路径规划问题重构为时空图（Space-Time Graph, STGraph）网络流模型，将时间单调性直接编码为有向无环图（DAG）的拓扑结构。这一变换从根本上消灭了标准Miller-Tucker-Zemlin（MTZ）模型中每一项Big-M约束，代之以结构上紧致的网络流守恒约束。在某大型电单车共享系统的真实运营数据上，STGraph模型的LP松弛与整数最优解之间的偏差仅为1.0%，并在156秒内证得全局最优——而三种传统MIP模型在1200秒时限内均无法收敛（gap 高达71%–88%），延迟约束回调方案更是暴露了结构性的时序不可行问题。

本文的剩余部分将这一框架分步展开。第2节将我们的工作定位于四个既有研究流派的交汇处。第3节形式化地定义了问题，陈述了核心随机假设，并推导了流体ODE库存动力学。第4节

建立了封闭效用评估框架，将连续时间随机积分降维为常数时间复杂度的代数求值。第5节介绍用于时空需求预测的Hurdle模型的架构与训练流程——这是为优化管线提供到达率和离开率估计值（ $\hat{\lambda}_j$ 、 $\hat{\rho}_j$ ）的上游环节。第6节给出了MIP路径规划模型并论证了向STGraph重构的动因。第7节详细阐述了STGraph构造和求解方法。第8节报告了计算实验与消融分析。第9节对关键运营参数进行了敏感性分析并验证了模型的时序泛化能力。第10节总结了研究的启示并指明了未来工作方向。

2 相关工作

我们的框架汲取了四个研究方向的成果并对其有所推进。为了能够更好地理解我们的工作，在何处与现有研究相交或不同，我们将逐一梳理各方向的基础性工作，并阐明我们的方法在何处延伸了——或有意识地偏离了——当前的技术前沿。

2.1 时空需求预测

用户到达率和离开率（ λ_j 、 ρ_j ）的准确估计是所有时间依赖型出行优化的先决条件。现代预测方法大致分为两个家族：以XGBoost [7]、LightGBM [15]和CatBoost [23]为代表的树集成方法，以及STGCN [32]、DCRNN [16]等图神经网络架构。就本研究而言，关键挑战不仅是预测精度，更在于**极端零膨胀**——超56%的grid一小时样本需求为零，标准模型在结构上无法输出精确零值，导致下游VRP优化中大量“假需求”grid污染候选集合。Hurdle模型 [19]通过在结构上分解零/非零决策与量级估计，可从根本上输出精确零值；在共享单车OD需求预测中，该方法已在零值率高达96%的场景下展现出显著优于单阶段模型的性能 [17]。我们采用两阶段Hurdle模型，在此基础上引入差异化的特征设计与三段式阈值决策以适应本问题的决策需求（详见第5节）。树模型产生的低方差参数估计亦确保其作为MIP目标系数时的数值稳定性。

2.2 平均场近似与流体极限

对大规模共享单车网络进行精确的离散状态建模将立即触发维度灾难：数百个grid上的电池电量联合状态空间呈天文数字规模。[4] 提供了逃离这一陷阱的基础性工具：他们证明，随着交互组件数量的增长，随机轨迹收敛于由ODEs控制的确定性流体极限。[12] 随后量化了平均场期望值近似的有限规模误差，其阶数为 $O(1/N)$ 。

这一方法论已在共享出行领域收获了丰硕的应用成果。[11] 使用平均场极限解耦了同质共享单车系统中的复杂局部排队效应，并设计了激励相容的调控机制。[6] 利用封闭排队网络的稳态流体极限，为网约车空车调度问题推导了渐近最优性界。近年来，[3] 和 [29] 将流体和平均场动力学分别应用于微出行领域的动态定价和大规模资源管理。我们对这一流派的贡献是双重的：我们将流体极限方法论扩展至**三状态电池库存模型**（低电量、即将耗尽、正常），该模型捕捉了电单车质量差异化的服务价值；同时，我们推导了可追踪换电后库存轨迹的闭式ODE解——使下游优化能够在不依赖数值积分的条件下评估换电干预的效果。

2.3 共享出行中的车辆路径规划与再平衡

我们工作的运营核心将经典车辆路径规划延伸至目标函数本身由随机系统动力学所塑造的设定。[24] 形式化的静态单车再平衡问题（SBRP）为传统单车共享系统奠定了路径-装载联合优化的基础框架；[25] 通过引入库存服务水平约束来防止缺货。然而，这些模型将被调配的商品（单车）视为均质且不可损耗的——这对于机械单车是充分的，但对于电池持续退化的电单车则远远不够。

针对电单车的文献尚处于起步阶段。[33] 通过马尔可夫链对电池换电操作进行了建模，证明联合优化电池库存与单车数量相较于解耦启发式算法的性能提升超过20%。[2] 更广泛地综述了电动汽车的换电架构，指出标准化和基础设施成本是推广的主要障碍。我们的模型在目标函数结构上与此前工作存在本质区别：我们并非最小化运营成本或未满足需求，而是最大化一个**质量加权的**服务效用，该效用区分了不同的电池状态（正常取全额权重、即将耗尽取80%、低电量取零）。这一效用结构使我们的路径规划问题与定向越野问题（OP）和收益路径问题（PTP）家族 [28, 14] 对齐——其目标是在时间预算约束下最大化收集的分值。在子回路消除方面，我们最初采用了Miller-Tucker-Zemlin（MTZ）模型 [8]，以其能够将可变且节点特异的服务时间吸收到时序追踪变量中——这一特性对我们的时间依赖效用至关重要；然而，MTZ的Big-M结构在LP松弛中产生极弱的上界（这是整数规划中广为人知的建模缺陷 [31]），Öncan等 [22] 对24种ATSP formulation的系统比较亦确认了MTZ的LP松弛强度显著弱于DFJ和multi-commodity flow formulation。Big-M对可解性的根本限制在第6节中得到系统论证，并推动了向STGraph模型的转型。值得指出的是，Mahmoudi与Zhou [18] 提出了State-Space-Time网络表示以求解带时间窗的取送货VRP——其将车辆携带状态嵌入时空网络的构造与本文STGraph具有方法论上的亲缘性。本文与Mahmoudi & Zhou的关键差异在于：(1) 目标函数由流体动力学导出而非固定运营成本；(2) 问题结构为可选节点+时间依赖效用而非强制性取送货。

2.4 Predict-then-Optimize范式

我们框架的架构——将随机预测通过结构上匹配的接口馈入确定性优化器——是Predict-then-Optimize（PtO）范式的具体实例化。[5] 综述了机器学习用于组合优化的方法论全景，并将预测与优化的接口确定为核心挑战。[9] 通过Smart “Predict, then Optimize”（SPO）框架形式化了这一挑战，主张预测模型应以决策损失（而非纯粹预测精度）为训练目标。[30] 更进一步，将可微优化层直接嵌入神经网络训练中，使决策质量的梯度信号能够端到端地回传至模型参数。

我们对PtO文献的贡献是架构性的而非算法性的。我们提供了使PtO在结构上可行的**数学接口**——针对时间依赖、随机库存动力学下的路径规划——这一问题上，预测与优化两个阶段历来仅靠启发式方法桥接。封闭效用函数 $U_j(u_j, y_j)$ 是该接口的关键支柱：它将连续时间的流体轨迹压缩为常数时间的代数求值，使得能够为每个grid、换电量和到达时刻预计算目标系数，从而将路径规划问题变为可精确MIP求解的形式。该接口是否能够通过SPO风格的面向决策的预测器训练被进一步紧致化，是我们将在第10节讨论的自然延伸方向。

3 问题描述与核心假设

3.1 问题背景与优化目标

我们考虑一个被划分为大量Grids的共享电单车服务系统，所有电单车分布在这些离散的grids上。用户行为具有高度随机性：在任意grid内，用户以随机方式到达，随机选择一辆单车出行，随后将单车随机归还至任意grid（包括出发grid）。若用户到达某grid时无可用的可服务车辆，则该次需求丢失——不仅造成用户体验的下降，也构成运营商的隐性损失。

在服务区域内，一名运营人员驾驶配备换电功能的服务车，在各grid间行驶并执行电池更换操作。所有备用电池存储于固定的充电柜中；服务车每次巡回仅能携带有限数量的电池。运营人员须周期性返回充电柜，将已耗尽电池充电并补充库存。我们的目标是在长度为 T 的规划周期内，生成一个动态调度方案——明确每个grid是否被访问以及应更换多少块电池。

现实中，共享电单车的电池电量分布是连续的，这使得精确计算极其复杂，需要逐车追踪——这一方法在大规模城市规划中并不可取。因此，我们将电单车划分为三种电池状态：低电量（剩余电量低于 20%）、即将耗尽（剩余电量介于 20% 至 50% 之间）和正常。为保证服务水平，低电量状态的车辆被视为不可用。在每个信息更新时刻（间隔为 T ），我们观测各grid中处于低电量、即将耗尽和正常状态的车辆数量。车辆状态仅在信息更新时刻发生变更；两次更新之间，各车的状态保持不变。对于该系统，我们的目标是最大化换电服务的总效用。

该过程可被刻画为一个闭环、可选节点、容量受限的车辆路径问题。与标准VRP模型相比，其显著特征是结构上高度复杂的非线性目标函数以及深度随机的系统动力学。为在保持本质随机特征的同时对系统进行可操作的抽象，我们引入以下假设。

3.2 核心随机假设

假设1（Poisson到达与离开假设）： 每个grid $j \in \mathcal{J}$ 上电单车的到达与离开过程分别服从速率为 ρ_j 和 λ_j 的独立Poisson过程（离开速率 λ_j 作为用户需求的代理变量）。Poisson假设是排队论中建模随机到达的经典范式 [27]，并在共享单车系统的数据驱动优化中被广泛采纳为合理近似 [21]：

$$N_{\text{in}}(t) \sim \text{Poisson}(\rho_j t), \quad N_{\text{out}}(t) \sim \text{Poisson}(\lambda_j t) \quad (3.1)$$

假设2（随机用户行为假设）： 对于服务区域内任意正在使用中的单车，其可能被归还至任意grid。因此，对于任意grid，到达车辆的电池状态分布可视为全局电池状态分布 Θ^{global} ，其中 Θ_k^{global} 表示处于状态 k 的车辆比例， $k \in \{\text{soon}, \text{normal}\}$ （由于low状态车辆无法正常骑行，故在此不考虑low状态车辆的比例，仅考虑soon,normal之间的相对关系）。同时，用户在出发站点从可用车辆集合中随机选取一辆。我们以 $\Theta_k^{\text{grid}}(t)$ 表示给定grid内时刻 t 处于状态 k 的车辆比例。

假设3（流体与期望近似假设）： 对于该系统，直接使用排队论结果将进一步加剧非线性，导致系统不可解。因此，我们将车辆数量视为连续流体，以速率替代离散事件，并以随机变量的期望值替代随机变量本身。在此近似下，系统动力学成为一个连续可微系统，使得我们能够获得解析解并进行优化。

对于任意grid j ，给定 $t = 0$ 时刻各状态 k 的初始车辆数 $n_{j,k}$ ，以及到达率 ρ_j 和离开率 λ_j ，

可服务车辆的库存演化由以下方程控制：

$$N_{j,k}(t) = n_{j,k} + \int_0^t \left[\rho_j \cdot \Theta_k^{\text{global}} - \lambda_j \Theta_{j,k}^{\text{grid}}(\tau) \right] d\tau \quad (3.2)$$

由于用户的随机性，到达车辆的状态分布在所有grid上均由同一全局分布近似。对每个固定grid j ，局部ODE具有自身的初始条件 $n_{j,k}$ 和速率 ρ_j, λ_j ，同时共享公共的全局比例 Θ_k^{global} 。局部比例定义为：

$$\Theta_{j,k}^{\text{grid}}(t) = \frac{N_{j,k}(t)}{N_j(t)}, \quad N_j(t) = \sum_{k=1}^2 N_{j,k}(t) \quad (3.3)$$

在该流体ODE中，我们仅追踪可服务状态 $k = 1, 2$ （即将耗尽和正常）；低电量状态保持排除在外，作为仅在换电时刻可转化为可服务库存的静态池。对 k 求和可得：

$$\begin{aligned} \sum_{k=1}^2 \frac{dN_{j,k}(t)}{dt} &= \sum_{k=1}^2 \left(\rho_j \Theta_k^{\text{global}} - \lambda_j \frac{N_{j,k}(t)}{N_j(t)} \right) \\ \frac{d}{dt} N_j(t) &= \rho_j \sum_{k=1}^2 \Theta_k^{\text{global}} - \lambda_j \frac{1}{N_j(t)} \sum_{k=1}^2 N_{j,k}(t) \end{aligned} \quad (3.4)$$

利用 $\sum_{k=1}^2 \Theta_k^{\text{global}} = 1$ 和 $\sum_{k=1}^2 N_{j,k}(t) = N_j(t)$ ，可简化为关于 $N_j(t)$ 的线性ODE：

$$\frac{dN_j(t)}{dt} = \rho_j - \lambda_j \quad (3.5)$$

在初始条件 $N_j(0) = N_{j,0} = \sum_{k=1}^2 n_{j,k}$ 下，积分可得闭式解：

$$N_j(t) = N_{j,0} + (\rho_j - \lambda_j)t \quad (3.6)$$

将此代回各状态的ODE，得到一个一阶线性非齐次ODE：

$$\frac{dN_{j,k}}{dt} + \frac{\lambda_j}{N_{j,0} + (\rho_j - \lambda_j)t} N_{j,k} = \rho_j \Theta_k^{\text{global}} \quad (3.7)$$

该方程为标准形式 $y' + P_j(t)y = Q_j(t)$ ，可通过积分因子法求解。根据 $\rho_j \neq \lambda_j$ 或 $\rho_j = \lambda_j$ ，出现两种情况。

若 $\rho_j \neq \lambda_j$ ，积分因子为：

$$I_j(t) = \exp \left(\int \frac{\lambda_j}{N_{j,0} + (\rho_j - \lambda_j)t} dt \right) = (N_{j,0} + (\rho_j - \lambda_j)t)^{\frac{\lambda_j}{\rho_j - \lambda_j}} \quad (3.8)$$

积分后可得：

$$N_{j,k}(t) = \left(n_{j,k} - \Theta_k^{\text{global}} N_{j,0} \right) \left(\frac{N_{j,0}}{N_{j,0} + (\rho_j - \lambda_j)t} \right)^{\frac{\lambda_j}{\rho_j - \lambda_j}} + \Theta_k^{\text{global}} (N_{j,0} + (\rho_j - \lambda_j)t) \quad (3.9)$$

若 $\rho_j = \lambda_j$ ，总可服务库存守恒 $N_j(t) \equiv N_{j,0}$ ，ODE退化为常系数线性方程，其解为：

$$N_{j,k}(t) = \Theta_k^{\text{global}} N_{j,0} + \left(n_{j,k} - \Theta_k^{\text{global}} N_{j,0} \right) e^{-\frac{\lambda_j}{N_{j,0}} t} \quad (3.10)$$

综上，逐gridODE系统的精确解析解为：

- 若 $\rho_j \neq \lambda_j$ (逐grid可服务库存非守恒):

$$N_{j,k}(t) = \underbrace{\left(n_{j,k} - \Theta_k^{\text{global}} N_{j,0} \right) \left(\frac{N_{j,0}}{N_{j,0} + (\rho_j - \lambda_j)t} \right)^{\frac{\lambda_j}{\rho_j - \lambda_j}}}_{\text{初始偏离的演化}} + \underbrace{\Theta_k^{\text{global}} (N_{j,0} + (\rho_j - \lambda_j)t)}_{\text{理论配额项的演化}} \quad (3.11)$$

- 若 $\rho_j = \lambda_j$ (逐grid可服务库存守恒):

$$N_{j,k}(t) = \underbrace{\Theta_k^{\text{global}} N_{j,0}}_{\text{稳态分布}} + \underbrace{\left(n_{j,k} - \Theta_k^{\text{global}} N_{j,0} \right) e^{-\frac{\lambda_j}{N_{j,0}} t}}_{\text{指数衰减的瞬态项}} \quad (3.12)$$

从物理含义上解释, 每项解的第一部分表示逐grid初始状态与理想全局配额之间的偏差。随时间推移, 这一偏差项衰减 (或被稀释), 逐grid的组成分布收敛于全局比例 Θ_k^{global} 。

4 系统动态与效用评估

4.1 自然状态下的库存动态

在无换电干预的条件下, 系统动态完全由用户需求驱动。任意grid内的状态分布 $\Theta_{j,k}^{\text{grid}}(t) = N_{j,k}(t)/N_j(t)$ 随时间逐渐收敛于全局分布 Θ_k^{global} , 而总库存 $N(t)$ 的演化取决于 ρ 与 λ 的关系: 当 $\lambda > \rho$ 时, $N(t)$ 逐渐下降并可能最终归零 (供给短缺); 当 $\lambda < \rho$ 时, 总库存持续增长 (可能出现过剩); 当 $\lambda = \rho$ 时, 总库存指数收敛至稳态, 稳态值与全局分布 Θ_k^{global} 相关。

在自然动态下, 对于每个grid j , 可用服务车辆数量为

$$N_{\text{serv},j}(t) = N_{j,\text{soon}}(t) + N_{j,\text{normal}}(t) \quad (4.1)$$

在该流体模型中, 当可用库存归零时将触发需求损失。记零库存状态的起始时刻为 t_0 (其满足不动点方程 $N_{\text{serv},j}(t_0) = 0$), 则在区间 $[t_0, T]$ 内的损失需求为

$$\text{LostDemand}_j = \int_{t_0}^T (\lambda_j - \rho_j) dt = (\lambda_j - \rho_j)(T - t_0) \quad (4.2)$$

对该系统而言, 任意节点的服务价值体现于对未来净需求的满足。从任意到达时刻 u_j 直至有效边界 $\min(t_0, T)$, 净服务价值可表达为质量加权的流出服务率与质量加权的流入稀释率之差:

$$S_j(u_j) = \int_{u_j}^{\min(t_0, T)} \left(\lambda_j (\Theta_{j,\text{normal}}^{\text{grid}}(t) + 0.8 \Theta_{j,\text{soon}}^{\text{grid}}(t)) - \rho_j (\Theta_{\text{normal}}^{\text{global}} + 0.8 \Theta_{\text{soon}}^{\text{global}}) \right) dt \quad (4.3)$$

4.2 瞬时换电后的库存动态

假设在时刻 u , 服务工人到达grid j 并执行换电操作。其操作规则如下:

- 换电仅适用于 low 和 soon 状态的车辆。换电后, 车辆被重置为 normal 状态并恢复完全可用性。

- 不同电池状态对应不同的服务质量：normal 为最优（100% 服务），low 为最差（0% 服务），soon 为中等（80% 服务水平）。
- 服务工人的车载电池数量有限，因此每次访问的换电量受到约束。工人能够识别grid内所有车辆的状态，并优先更换 low 状态车辆，若有剩余容量再更换 soon 状态车辆。

在上述假设下，若服务工人在时刻 u 执行 y 次换电，换电后的库存仍遵循相同的 ODE 结构，但初始条件发生了改变。换电后的总库存与各状态存量如下：

$$\tilde{N}_{j,0} = N_j(u) + \min\{y_j, N_{j,\text{low}}(u)\} \quad (4.4)$$

$$\tilde{n}_{j,k} = \begin{cases} N_{j,k}(u) - \min\{y_j, N_{j,\text{low}}(u)\} & \text{if } k = \text{low} \\ N_{j,k}(u) - \max\{0, y_j - N_{j,\text{low}}(u)\} & \text{if } k = \text{soon} \\ N_{j,k}(u) + y_j & \text{if } k = \text{normal} \end{cases} \quad (4.5)$$

换电后的库存 $\tilde{N}_{j,k}(t)$ ($t > u$) 遵循第3节推导的相同解析形式，仅需将初始条件 $n_{j,k}$ 替换为 $\tilde{n}_{j,k}$ ，并将时间原点平移至 u ：

- 若 $\rho \neq \lambda$ ：

$$\tilde{N}_{j,k}(t) = \left(\tilde{n}_{j,k} - \Theta_k^{\text{global}} \tilde{N}_{j,0} \right) \left(\frac{\tilde{N}_{j,0}}{\tilde{N}_{j,0} + (\rho - \lambda)(t - u)} \right)^{\frac{\lambda}{\rho - \lambda}} + \Theta_k^{\text{global}} (\tilde{N}_{j,0} + (\rho - \lambda)(t - u)) \quad (4.6)$$

- 若 $\rho = \lambda$ ：

$$\tilde{N}_{j,k}(t) = \Theta_k^{\text{global}} \tilde{N}_{j,0} + \left(\tilde{n}_{j,k} - \Theta_k^{\text{global}} \tilde{N}_{j,0} \right) e^{-\frac{\lambda}{\tilde{N}_{j,0}}(t-u)} \quad (4.7)$$

换电服务的本质在于通过改变 ODE 的初始条件来调整系统的动态演化轨迹，从而达到延迟缺货的目的。记 t_0 为未换电时的原始缺货点， $\tilde{t}_0$ 为换电后的新缺货点。整个规划周期 T 以换电时刻 u 为界被分为两段：在 $t \leq u$ 区间内，系统按自然动态演化；在 $t > u$ 区间内，换电干预发生作用。

然而，由于 soon 状态与 normal 状态的车辆所提供的可骑行距离存在显著差异，二者不能被视为提供同等服务水平的资源。定义 $\tilde{\Theta}_{j,k}^{\text{grid}}(t) = \tilde{N}_{j,k}(t)/\tilde{N}_j(t)$ 以追踪换电后的状态分布。在电动车用户行为研究中，实地试验表明用户通常仅利用约80%的可用续航里程，保留约20%作为心理安全缓冲——即“舒适里程”仅约为实际里程的80% [10]。据此，我们对 soon 状态赋予80%的服务权重，以反映用户因里程焦虑导致的效用折扣。换电后的服务价值为：

$$\tilde{S}_j(u_j, y_j) = \int_{u_j}^T \left(\lambda_j (\tilde{\Theta}_{j,\text{normal}}^{\text{grid}}(t) + 0.8 \tilde{\Theta}_{j,\text{soon}}^{\text{grid}}(t)) - \rho_j (\Theta_{\text{normal}}^{\text{global}} + 0.8 \Theta_{\text{soon}}^{\text{global}}) \right) dt \quad (4.8)$$

换电操作的边际效用即为服务价值之差：

$$U_j(u_j, y_j) = \tilde{S}_j(u_j, y_j) - S_j(u_j) \quad (4.9)$$

4.3 质量调整后的封闭效用函数

为了在不引入高维随机变量的前提下精确刻画 normal 与 soon 状态之间因用户”里程焦虑”产生的服务水平差异，我们基于瞬时期望质量定义了一个连续的服务评估框架。由于用户随机选择可用车辆，在时刻 t 选中状态 k 车辆的概率正比于其瞬时库存比例 $\Theta_{j,k}^{\text{grid}}(t) = N_{j,k}(t)/N_j(t)$ 。我们采用以下约定：

- 在自然动态下，low 状态车辆不参与可用库存的 ODE 演化，仅作为在换电瞬间可转化的静态库存池。
- 若到达时间 $u_j \geq \tau_0$ （或换电后 $u_j \geq \tilde{\tau}_0$ ），则该节点在剩余周期内不提供净服务价值。
- 运营效用 $U_j(u_j, y_j)$ 在优化中被截断为非负值。

在 soon 状态存在 20% 服务降级的前提下，从到达时刻 u_j 至有效边界 $\tau_0 = \min(t_0, T)$ 所收集的基线净服务价值为：

$$S_j(u_j) = \int_{u_j}^{\tau_0} \left[\lambda_j \left(1.0 \cdot \frac{N_{j,\text{normal}}(t)}{N_j(t)} + 0.8 \cdot \frac{N_{j,\text{soon}}(t)}{N_j(t)} \right) - \rho_j \left(1.0 \cdot \Theta_{\text{normal}}^{\text{global}} + 0.8 \cdot \Theta_{\text{soon}}^{\text{global}} \right) \right] dt \quad (4.10)$$

若直接对此积分进行数值求解，其计算代价极高。然而，我们可以利用 ODE 系统的一个结构性特征来避免数值积分。将第3节中 $k = \text{normal}$ 和 $k = \text{soon}$ 的控制方程分别乘以对应的质量权重（1.0 和 0.8）并线性相加：

$$\begin{aligned} \frac{d}{dt} (N_{j,\text{normal}}(t) + 0.8N_{j,\text{soon}}(t)) &= \rho_j \left(\Theta_{\text{normal}}^{\text{global}} + 0.8\Theta_{\text{soon}}^{\text{global}} \right) \\ &\quad - \frac{\lambda_j}{N_j(t)} (N_{j,\text{normal}}(t) + 0.8N_{j,\text{soon}}(t)) \end{aligned} \quad (4.11)$$

将此式与被积函数对比，可发现一个关键洞察：系统净服务效用的流出率恰好等于系统内部”质量加权库存”总导数的相反数。根据微积分基本定理，该积分直接化简为边界求值：

$$S_j(u_j) = [N_{j,\text{normal}}(u_j) + 0.8N_{j,\text{soon}}(u_j)] - [N_{j,\text{normal}}(\tau_0) + 0.8N_{j,\text{soon}}(\tau_0)] \quad (4.12)$$

在时刻 u_j 完成 y_j 块电池的换电后，库存瞬间跃升为 $\tilde{n}_{j,k}$ 。换电后的服务价值遵循完全相同的数学结构：

$$\tilde{S}_j(u_j, y_j) = [\tilde{n}_{j,\text{normal}} + 0.8\tilde{n}_{j,\text{soon}}] - [\tilde{N}_{j,\text{normal}}(\tilde{\tau}_0) + 0.8\tilde{N}_{j,\text{soon}}(\tilde{\tau}_0)] \quad (4.13)$$

其中 $\tilde{\tau}_0 = \min(\tilde{t}_0, T)$ 为换电所延缓的新的有效服务上限。

净运营效用 $U_j(u_j, y_j)$ 为换电前后服务价值的边际增益：

$$U_j(u_j, y_j) = \tilde{S}_j(u_j, y_j) - S_j(u_j) = \Delta_{\text{swap}} - \left[\left(\tilde{N}_{j,\text{normal}}(\tilde{\tau}_0) + 0.8\tilde{N}_{j,\text{soon}}(\tilde{\tau}_0) \right) - (N_{j,\text{normal}}(\tau_0) + 0.8N_{j,\text{soon}}(\tau_0)) \right] \quad (4.14)$$

其中 Δ_{swap} 表示在换电瞬间注入系统的净服务质量增量：

$$\Delta_{\text{swap}} = \tilde{n}_{j,\text{normal}} - N_{j,\text{normal}}(u_j) + 0.8(\tilde{n}_{j,\text{soon}} - N_{j,\text{soon}}(u_j)) \quad (4.15)$$

结合优先换电逻辑（先 low 后 soon）， Δ_{swap} 可显式表达为 y_j 的极简函数：

$$\Delta_{\text{swap}} = \min\{y_j, N_{j,\text{low}}(u_j)\} + 0.2 \max\{0, y_j - N_{j,\text{low}}(u_j)\} \quad (4.16)$$

该闭式解提供了理论严谨且计算极轻量的评估原语：将复杂的连续时间随机积分降维为常数时间复杂度的代数运算，使效用函数能够直接内嵌于大规模 MIP 路由优化之中。

至此，我们已经建立了从系统状态到换电效用的完整理论框架：给定各grid的到达率和离开率（ λ_j 、 ρ_j ）以及初始电池库存，流体ODE系统确定了任意时刻的库存状态，闭式效用函数 $U_j(u_j, y_j)$ 将任意换电操作映射为边际效用值。框架中尚缺的环节是**如何从数据中获取速率参数 λ_j 和 ρ_j** ——这是第5节（时空需求预测）的任务，也是Predict-then-Optimize管线中”Predict”阶段的核心。第6–7节随后完成”Optimize”阶段，将预计算的效用张量嵌入STGraph-MIP模型以生成最优换电路由。

5 时空需求预测

本文优化框架以每个grid的用户流出率 λ_j 和流入率 ρ_j 为核心输入——它们驱动流体ODEs系统（第3节）并决定换电操作的边际效用（第4节）。然而，在1小时粒度、H3分辨率8的grid划分下，测试集中**56.16%（rent）和55.96%（return）的样本真实需求为零**。标准Poisson回归的log-link（ $\hat{y} = \exp(\eta) > 0$ 恒成立）或树模型的叶节点均值使单阶段模型在结构上无法输出精确零值——三种基线模型对56%的真实零需求样本100%输出正数预测，系统性地高估了需求的空间分布密度。这种零膨胀特征引入了一个具有不对称后果的建模困境：假阳性导致浪费访问，假阴性导致服务缺失。本节构建两阶段Hurdle预测模型以从结构上解决该问题。

5.1 模型架构与特征设计

Hurdle模型 [19]将零膨胀计数数据的生成过程分解为两个序贯阶段：分类器判断”是否会有需求”，回归器估计”需求有多大”。然而，标准Hurdle的概率乘积 $\hat{y} = \hat{\pi}(\mathbf{x}) \cdot \hat{\mu}_{\text{pos}}(\mathbf{x})$ 仅产生期望值估计器——分类器输出的非零概率使最终预测永不为零。为突破这一局限，我们引入三项关键创新构成四阶段训练管线（图1）：




图 1: CatBoost Hurdle四阶段训练管线

差异化特征设计：分类器使用全部39个特征（表1），特别是7个零需求检测特征和5个零需求交互特征（如`lag_zero_x_night`、`zero_momentum_rent`），显式编码“零惯性×时间上下文”的组合信号以缩小决策边界搜索空间；回归器排除12个零值专属特征，仅使用27个量级特征（含`temp_squared`等多项式交互项）。**独立超参调优：**分类器`depth=12`配合`L2=6.0`防止过拟合，自动计算`scale_pos_weight`（ ≈ 1.2 ）校准类别不平衡；回归器`depth=10`专注正样本量级分布拟合。**三段式阈值优化：**将验证集按时段分为Peak（7–9, 17–19时）、Shoulder（6, 10–16, 20–22时）和Night（0–5时），每段在Poisson退化约束下独立搜索最优 $\tau \in [0.01, 0.89]$ 。最终预测由式(5.1)给出：

$$\hat{y} = \begin{cases} 0, & \text{if } \hat{\pi}(\mathbf{x}) < \tau_{\text{seg}}(\mathbf{x}) \\ \hat{\pi}(\mathbf{x}) \cdot \hat{\mu}_{\text{pos}}(\mathbf{x}), & \text{if } \hat{\pi}(\mathbf{x}) \geq \tau_{\text{seg}}(\mathbf{x}) \end{cases} \tag{5.1}$$

表 1: 预测模型输入特征集（v5，39个特征）

类别（特征数）	特征名称
空间 (3)	h3, latitude, longitude
时间 (5)	month, day_of_week, is_weekend, hour, is_rush_hour
气象 (4)	temperature, wind_level, rain_level, temp_x_rain
历史需求 (4)	rent_mean_7d, return_mean_7d, lag_nb_rent, lag_nb_return
电池状态 (4)	normal_power_bike_count, soon_low_power_bike_count, low_power_bike_count, available_power_bike_count
零需求检测 (7)	lag_rent_is_zero, lag_return_is_zero, rent_mean_7d_low, return_mean_7d_low, is_night, lag_both_zero, lag_both_low
时间循环编码 (4)	hour_sin, hour_cos, day_of_week_sin, day_of_week_cos
零需求交互 (5)	lag_zero_x_night, lag_zero_x_rush, low_demand_x_night, zero_momentum_rent, zero_momentum_return
量级交互 (3)	temp_squared, rent_return_lag_interaction, bike_count_interaction

评估采用四层递进体系：全局回归指标（Poisson偏差、RMSE、MAE——注意Poisson偏差在 $y = 0$ 时等于 $2\hat{y}$ ，系统性偏袒不判零的模型），零膨胀分解指标（Zero Recall/Precision/F1），决策影响指标（WVR: 浪费访问率, MDR: 漏服务率, TDB: 需求总量偏差, MAPZ: 零样本平均浪费预测值），以及统计检验（McNemar检验、分桶分析、消融实验）。本文以MAE为首要全局准确度标准——其对零值判对/判错的惩罚是对称的。

5.2 对比实验与消融分析

所有模型共享39个输入特征，在相同训练/验证/测试划分（时间切分，682,920训练/292,680测试样本）下训练。对比基线包括CatBoost（CB, `depth=10`, Poisson）、LightGBM（LGB, Poisson, 63叶）和Random Forest（RF, 1500棵树, `depth=22`）。表2汇总测试集核心指标，同时报告消融变体CB_Hurdle_no_ τ （ $\tau = 0$ ，共享同一分类器和回归器）以分离阈值优化的贡献。

结果揭示三层核心发现。**(1) 零值识别的结构性垄断：**三种经典单阶段模型均无法准确预测零需求的存在，CB_Hurdle是唯一具备零值识别能力的模型（rent: Zero Recall=51.2%, Zero Precision=97.9%; McNemar $\chi^2 > 84,000$, $p < 10^{-6}$ ）。**(2) Poisson偏差系统性偏袒不判零的模型：**CB_Hurdle_no_ τ 的Poisson偏差（1.0311）优于完整版（1.1496），但WVR=56.16%——提供干净的因果证据：Poisson偏差在此场景下奖励从不判零的模型，不是可靠的模型选

表 2: 四种模型在测试集上的性能对比

模型	Poisson↓	MAE↓	Zero F1↑	WVR↓	MDR↓	TDB
目标: rent (真实零值率 56.16%)						
Random Forest	1.0644	1.0991	N/A	56.16%	0.00%	—
CatBoost	1.0703	1.0823	N/A	56.16%	0.00%	—
LightGBM	1.0894	1.1334	N/A	56.16%	0.00%	—
CB Hurdle	1.1496	1.0564	0.6727	27.39%	0.61%	−2.74%
<i>CB_Hurdle_no_τ</i>	<i>1.0311</i>	<i>1.0662</i>	<i>N/A</i>	<i>56.16%</i>	<i>0.00%</i>	<i>−2.26%</i>
目标: return (真实零值率 55.96%)						
Random Forest	1.1708	1.1619	N/A	55.96%	0.00%	—
CatBoost	1.1493	1.1340	N/A	55.96%	0.00%	—
LightGBM	1.2421	1.2546	N/A	55.96%	0.00%	—
CB Hurdle	1.2952	1.1084	0.6421	29.13%	0.77%	−6.94%
<i>CB_Hurdle_no_τ</i>	<i>1.1395</i>	<i>1.1234</i>	<i>N/A</i>	<i>55.96%</i>	<i>0.00%</i>	<i>−6.21%</i>

择标准。(3) 决策层面双重优势：WVR从56.16%降至27.39%（避免51%的不必要站点访问），TDB仅−2.74%（最接近真实需求总量），MDR仅0.61%。

为量化各组件的独立贡献，利用已训练组件构建三个消融变体（表3）。结果揭示清晰的因果链：分类器赋予零值识别能力（移除后Zero F1丧失、WVR回到56%），回归器保障量级精度（移除后MAE从1.06爆炸至3.28），阈值优化将理论可能转化为实际效益（移除后WVR从27%反弹至56%）。三个组件各司其职且不可替代。

表 3: 消融实验：Hurdle各组件边际贡献（rent目标）

变体	MAE↓	Zero F1↑	WVR↓	TDB	说明
CB_Hurdle（完整版）	1.0564	0.6727	27.39%	−2.74%	分类器+回归器+三段式τ
<i>CB_Hurdle_no_τ</i>	1.0662	N/A	56.16%	−2.26%	移除阈值（τ = 0）
<i>CB_Classifier_Only</i>	3.2828	0.7005	25.48%	+68.69%	移除回归器
<i>CB_Regressor_Only</i>	1.7089	N/A	56.16%	+33.17%	移除分类器

为验证Hurdle优势的空间分布，将测试集按历史需求均值分为四个桶（表4）。Hurdle优势在Q2（零值率67.3%）和Q3（零值率28.2%）达到峰值——正是决策信息最不确定的“灰色地带”。夜间（零值率约80%）的Zero F1=0.7172，验证了三段式阈值优化的针对性收益。

5.3 对下游优化的结构性支撑

回归器条件期望 $\hat{\mu}_{\text{pos}}(\mathbf{x})$ 生成流体ODEs所需的速率参数 $\hat{\lambda}_j$ 和 $\hat{\rho}_j$ 。CB_Hurdle的两阶段输出对STGraph路径优化（第7节）具有独立且互补的运营价值。分类器概率 $\hat{\pi}(\mathbf{x})$ 直接服务于Geo-Fencing空间剪枝：当一个grid在所有时间断点的需求发生概率均低于 τ_{seg} 时，可安全排除出候选访问集合——97.9%的判零精确率确保剪枝的高置信度，WVR从56%降至27%意味着候选grid集合的删减效率近乎翻倍，从而降低MIP求解的计算负担。TDB仅−2.74%验证了需求总量校准

表 4: 按历史零值率分桶的误差分析 (rent目标)

分桶	真实零值率	CB_Hurdle RMSE	CatBoost RMSE	Hurdle优势
Q1 (极低需求)	90.9%	0.3741	0.3698	-0.0043
Q2 (低需求)	67.3%	0.7785	0.8032	+0.0247
Q3 (中需求)	28.2%	1.6018	1.6215	+0.0198
Q4 (高需求)	2.3%	4.7259	4.7181	-0.0078

的可靠性，对车队规模部署决策具有直接指导意义。

综上，CB_Hurdle通过两阶段分解在结构上解决了单阶段模型无法输出零值的根本缺陷——分类器赋予零值识别能力（从无到有），回归器提供量级精度（MAE降低68%），阈值优化将理论可能转化为实际决策效益（WVR减半）——三个组件各司其职且不可替代。

6 全局路由优化

建立了任意节点的效用评价体系，并利用Hurdle模型输出流体ODEs求解所需的速率参数后，调度问题自然转化为：在车载电池容量 C 和规划周期 T 的双重约束下，选择访问哪些grid、以何种顺序访问、在每个grid换多少块电池，使得全路径的效用总和最大。这是一个可选节点、容量受限、时间受限的车辆路径问题，其核心难点在于目标函数的非线性——效用 $U_j(u_j, y_j)$ 通过 ODE 导出的闭式解同时依赖于到达时刻 u_j 和换电量 y_j 。

通过对效用函数的进一步分析，我们能够发现 $U_j(u_j, y_j)$ 在不同的节点 j 的参数组合下，并非全局凸或全局凹。为将其嵌入 MIP 求解器，我们采用分段线性插值（Piecewise Linear Approximation, PLA）对效用函数进行离散化。通过在到达时间和换电量的二维空间上构建一个grid，将连续的效用函数近似为一系列线性片段，从而将非线性优化问题转化为一个可求解的 MIP 问题。令 $\mathcal{N} = \mathcal{J} \cup \{0\}$ ，其中 0 为充电柜。决策变量包括： $x_{ij} \in \{0, 1\}$ （路由）、 $v_j \in \{0, 1\}$ （访问）、 $y_j \in \mathbb{Z}^+$ （换电量）和 $u_j \geq 0$ （到达时间）。记 c 为单块电池的换电耗时， a_{ij} 为行驶时间。基础 MIP 模型如下：

$$\max \sum_{j \in \mathcal{J}} \sum_{y \in \mathcal{Y}} \sum_{s \in \mathcal{S}} \Omega_j(y, \tau_s) \cdot \lambda_{j,y,s} \quad (6.1)$$

$$\text{s.t.} \quad \sum_{i \in \delta^-(j)} x_{ij} = v_j, \quad \sum_{k \in \delta^+(j)} x_{jk} = v_j, \quad \forall j \in \mathcal{J} \quad (6.2)$$

$$\sum_{j \in \mathcal{J}} x_{0j} = \sum_{i \in \mathcal{J}} x_{i0} \leq 1 \quad (6.3)$$

$$y_j \leq C \cdot v_j, \quad \sum_{j \in \mathcal{J}} y_j \leq C \quad (6.4)$$

$$u_j \geq u_i + c \cdot y_i + a_{ij} - M(1 - x_{ij}), \quad \forall i \in \mathcal{N}, j \in \mathcal{J}, i \neq j \quad (6.5)$$

$$u_i + c \cdot y_i + a_{i0} - M(1 - x_{i0}) \leq T, \quad \forall i \in \mathcal{J} \quad (6.6)$$

$$u_j = \sum_{y \in \mathcal{Y}} \sum_{s \in \mathcal{S}} \tau_s \cdot \lambda_{j,y,s}, \quad \forall j \in \mathcal{J} \quad (6.7)$$

$$x_{ij}, v_j \in \{0, 1\}, \quad y_j \in \mathbb{Z}^+, \quad u_j \geq 0 \quad (6.8)$$

其中 $\Omega_j(y, \tau_s)$ 为预计算的效用张量——表示在离散时刻 τ_s 到达 grid j 并换电 y 块的边际效用； $\lambda_{j,y,s}$ 为 SOS2 插值权重变量，用于将连续到达时间映射至离散断点； $\mathcal{Y}$ 和 $\mathcal{S}$ 分别为离散换电量和时间断点索引集合。

约束 (6.2) 保证流守恒，(6.3) 保证充电桩出发与返回一致性，(6.4) 为换电容量约束，(6.5) 为 MTZ 子回路消除与时间推进约束，(6.6) 为规划周期截止约束。

6.1 MTZ Big-M 约束的结构性缺陷

该模型的核心计算困难源于约束 (6.5)。这是一个典型的 Big-M 约束：当 x_{ij} 在 LP 松弛中取分数值时，松弛项 $M(1 - x_{ij})$ 使得到达时间 u_j 与 u_i 完全解耦。求解器可以通过在大量弧段上分配微小分数流，在满足所有流守恒约束的同时构造一个时间推进完全虚构的伪可行解。这导致根节点 LP 松弛产生极为松散的上界——通常高达真实整数最优解的 2-3 倍——使分支定界几乎无法有效剪枝。

我们先后开发并分析了四种在结构上逐步演进的 MIP 建模架构。表 5 从时间编码、子回路消除、Big-M 依赖、LP 紧致性来源和时序保证机制五个设计维度对四种架构进行了系统对比。以下逐一剖析其结构特征与预期行为，定量验证将在第 8 节统一呈现。

方案A：SOS2-PLA + 全量 MTZ。最直接的实现方式：使用 SOS2 (Special Ordered Set of type 2) 约束对效用函数进行分段线性插值，将连续到达时间映射至离散断点的凸组合；搭配完整的 $O(N^2)$ 条显式 MTZ 不等式消除子回路并推进时间。该方案的**结构性缺陷**在于：每条 MTZ 约束均含 Big-M 项 $M(1 - x_{ij})$ ，当 x_{ij} 在 LP 松弛中取分数值时， u_j 与 u_i 完全解耦——求解器可通过在大量弧段上分配微小分数流构造时间推进完全虚构的伪可行解，导致根节点 LP 严重高估真实最优值。此外，SOS2 的特殊有序结构引入了 $O(P \cdot N \cdot |\mathcal{Y}|)$ 个额外约束和分支负担。

方案B：Delta 增量编码 + 显式 MTZ。将 SOS2 替换为二元 delta 阶梯变量 $\delta_1 \geq \delta_2 \geq \dots \geq \delta_P$ ：到达时间的凸组合性质由 delta 链的单调递减结构精确刻画，消除了 SOS2 的特殊有

序结构开销。然而，子回路消除和时序推进仍依赖显式 MTZ 约束，消除 SOS2 结构并未触及真正的瓶颈——只要 Big-M 项仍在约束矩阵中，LP 松弛的松散性就不会有本质改善。

方案C: Delta + MCF 流约束 + 延迟 MTZ 回调。在方案B的基础上做了两项增强：(1) 引入单商品流（MCF）约束—— $f_{ij} \leq C \cdot x_{ij}$ 以及每个节点的电池流量守恒——加强路由变量之间的 LP 耦合强度；(2) 将 $O(N^2)$ 条 MTZ 约束从显式行转化为 LazyConstraints 回调（MIPSOL），仅在发现整数可行解时才注入违规的时序割，试图规避 Big-M 对 LP 松弛的持续污染。该方案的**结构性风险**是双重的：(i) LazyConstraints=1 迫使 Gurobi 禁用割平面生成（Cuts=0）和激进预求解，B&B 搜索被结构性阻断；(ii) 延迟回调仅在当前分支的整数解上触发，无法阻止兄弟分支产生新的时序违规解，且注入的割无法被求解器进行全局传播——时序可行性从“被保证”降格为“被抽查”，且抽查本身也是不完整的。

方案D: 时空图网络流模型（Space-Time Graph, STGraph）。该方案的根本性突破在于：将时间从约束右侧提升为图的显式维度，彻底消灭了所有 Big-M 项。核心思想是将连续时间离散化并嵌入有向无环图（DAG）的拓扑结构中——每个时空节点 (i, s) 表示“在时刻 τ_s 位于节点 i ”，每条有向边从低时间步指向高时间步，天然蕴含了时间的不可逆性。在此框架下：(1) 子回路在 DAG 中结构上不可能出现，MTZ 约束不再需要；(2) 时序可行性不再是需要验证的约束，而是图的定义——从 (i, s_1) 到 (j, s_2) 的弧天然满足 $s_2 \geq s_1 + 1$ ；(3) 所有时间同步约束退化为网络流平衡方程，约束矩阵本质上是具有全幺模子结构的网络流矩阵，LP 松弛自然紧致。代价是变量数量大幅增加——时空扩展将空间弧乘以时间维度和换电量维度——但这通过 KNN 空间稀疏化和 Geo-Fencing 效用过滤得到了有效控制。

表 5: 四种 MIP 架构的设计维度对比

设计维度	A: SOS2+MTZ	B: Delta+MTZ	C: Delta+MCF+Lazy	D: STGraph
时间编码	SOS2凸组合权重	Delta二元阶梯	Delta二元阶梯	时空节点显式离散
子回路消除	显式MTZ（Big-M）	显式MTZ（Big-M）	延迟MTZ回调	DAG拓扑（无需MTZ）
Big-M依赖	全量 $O(N^2)$ 条	全量 $O(N^2)$ 条	隐藏于回调中	零 Big-M
LP紧 致 性 来 源	—（Big-M污染）	—（Big-M污染）	—（Big-M仍在LP中）	网络流全幺模子结构
时序保证方式	代数不等式	代数不等式	Callback抽查（脆弱）	DAG拓扑保证
求解器兼容性	完整预求解+割平面	完整预求解+割平面	预求解受限，割平面禁用	完整预求解+割平面

从设计维度对比中可以清晰地看到一条演进脉络：方案A→B 优化了编码效率但未触及核心矛盾（Big-M），方案B→C 试图通过延迟回调规避 Big-M 但付出了求解器能力降级的代价，唯有方案D 通过将时间单调性从代数约束提升为图拓扑的定义性质，从根本上同时解决了 LP 松弛紧致性和时序可行性两个难题。第 8 节的受控实验将对上述结构性预判进行系统的实证检验。

7 模型求解

7.1 求解管线总览

完整的求解管线包含六个阶段：

1. **数据加载与快照提取。**从预测数据集中提取目标时刻的全区域快照，包括每个 H3 六边形grid的 low/soon/normal 车辆数量、预测租还速率 $\hat{\lambda}_j, \hat{\rho}_j$ ，以及grid中心坐标。
2. **旅行时间矩阵构建。**基于 Haversine 球面距离公式，以恒定车速 30 km/h 计算所有grid对之间的行驶时间。充电柜位置取所有活跃grid的几何质心。
3. **静态效用张量预计算 (PLA)。**在 P 个等距时间断点 $\{\tau_0 = 0, \tau_1, \dots, \tau_P = T\}$ 上，对每个grid j 的每个可行换电量 $y \in \mathcal{Y}$ ，调用第4节的封闭效用函数 $U_j(y, \tau_s)$ ，构成三维效用张量 $\Omega_j(y, \tau_s)$ 。该张量是下游 MIP 模型中目标函数系数的唯一来源。
4. **Geo-Fencing 空间剪枝。**剔除在所有 (y, s) 组合下效用恒为零的grid。对剩余grid应用 K 近邻 (KNN) 空间稀疏化：每个节点仅保留行驶时间最短的 $K = 50$ 个邻居作为候选弧段，压缩决策空间约 90%，同时保留最具物理意义的近邻转移。
5. **时空图构建与 MIP 求解。**基于 KNN 空间网络和时间离散化构建时空扩展图，声明网络流决策变量与辅助联动变量，施加流守恒、容量、单次访问和联动约束，注入贪心热启动初始解，调用 Gurobi 进行单阶段 branch-and-cut 求解。
6. **路由解码与时序审计。**沿 DAG 拓扑追踪激活的时空弧，还原为一维物理路由序列。基于真实的 Haversine 几何进行时序一致性的双向交叉校验。

7.2 时空图 (STGraph) 构建方法

STGraph 的核心思想是将“时间”从约束的右侧提升为图的显式维度。令 $\mathcal{T} = \{0, 1, \dots, P\}$ 为离散时间步索引集合，每个时间步 $s \in \mathcal{T}$ 对应物理时刻 τ_s 。时空图中的节点为二元组 (i, s) ，表示“车辆在时刻 τ_s 位于节点 i ”。时空图中的有向弧为五元组 $e = (i, s_1, j, s_2, y)$ ，表示“车辆在时刻 τ_{s_1} 从节点 i 出发，在 i 处换电 y 块，行驶 a_{ij} 时间后，在时刻 τ_{s_2} 到达节点 j ”。

时间右取整对齐。由于物理到达时间很少恰好落在离散断点上，我们采用右取整 (right-rounding) 策略：

$$s_2 = \min\{s \in \mathcal{T} : \tau_s \geq \tau_{s_1} + c \cdot y + a_{ij}\} \quad (7.1)$$

这确保了所有非充电柜弧满足 $s_2 \geq s_1 + 1$ ，使时空图天然构成 DAG——时间单调性成为一种拓扑性质而非需要施加的约束。右取整引入的保守时间松弛最多为一个离散间隔的宽度，其大小可由时间分辨率 P 控制。

KNN 空间网络稀疏化。对于 $N = 465$ 个活跃grid，全连接空间网络包含 $N(N - 1) \approx 216,000$ 条弧。乘以 $P = 10$ 个时间步和 $|\mathcal{Y}| = 10$ 种换电选择后，决策变量数量将达数千万。KNN 稀疏化 ($K = 50$) 结合时间步可行性过滤和弧段行驶时间裁剪 ($\leq 0.2h$)，将实际可行弧段压缩至约 12 万条空间弧——时空扩展后形成约 213 万决策变量，缩减约两个数量级。

时空弧枚举。时空弧分为两类：

- 首发弧: $(0, 0) \rightarrow (j, s_2)$, $y = 0$, 对所有从充电柜出发的行驶时间在 T 内的grid j 。
- 转移弧: $(i, s_1) \rightarrow (j, s_2)$, $y \in \mathcal{Y}$, 对所有 $s_1 < P$, $j \in \text{KNN}(i)$, 且右取整到达步 $s_2 \leq P$ 。

7.3 STGraph-MIP 数学模型

令 $\mathcal{E}$ 为所有时空弧的集合, 对每条弧 $e = (i^e, s_1^e, j^e, s_2^e, y^e)$ 定义二元决策变量 $x_e \in \{0, 1\}$ 。辅助联动变量 v_j, u_j, y_j 用于与传统 VRP 结果解析管线兼容。

7.3.1 目标函数

$$\max \sum_{e \in \mathcal{E}: i^e \neq 0} \Omega_{i^e}(y^e, \tau_{s_1^e}) \cdot x_e \quad (7.2)$$

每条弧的目标系数直接从预计算的效用张量中按弧的出发节点、换电量和出发时间步查表取值。效用语义与第4节一致: 效用由到达时间和换电量决定; 在离散 STGraph 中, 到达时间 u_j 由离散步 τ_{s_1} 近似。

7.3.2 时空流守恒约束

对每个grid j 和每个时间步 s , 流入等于流出:

$$\sum_{e \in \delta_{ST}^-(j, s)} x_e = \sum_{e \in \delta_{ST}^+(j, s)} x_e, \quad \forall j \in \mathcal{J}, s \in \mathcal{T} \quad (7.3)$$

其中 $\delta_{ST}^-(j, s)$ 和 $\delta_{ST}^+(j, s)$ 分别为时空节点 (j, s) 的入弧和出弧集合。这是标准网络流平衡约束。关键在于, 这一组约束一次性替代了传统模型中所有的 MTZ 子回路消除、时间推进和时间同步约束——在 DAG 中, 流守恒本身就保证了物理可行性。

7.3.3 充电柜边界与单次访问约束

$$\sum_{e \in \delta_{ST}^+(0, 0)} x_e \leq 1 \quad (7.4)$$

$$\sum_{s=1}^P \sum_{e \in \delta_{ST}^-(0, s)} x_e = \sum_{e \in \delta_{ST}^+(0, 0)} x_e \quad (7.5)$$

$$\sum_{s_1=0}^{P-1} \sum_{e \in \delta_{ST}^+(j, s_1)} x_e \leq 1, \quad \forall j \in \mathcal{J} \quad (7.6)$$

约束 (7.4) 限制至多一辆服务车从充电柜出发。约束 (7.5) 确保出发的车辆必须在时间步 1 至 P 之间的某一步返回充电柜。约束 (7.6) 保证每个物理grid最多被访问一次, 杜绝车辆在不同时间步反复访问同一grid以重复获取效用。

7.3.4 全局容量约束

$$\sum_{e \in \mathcal{E}} y^e \cdot x_e \leq C \quad (7.7)$$

全程累积换电总量不超过车载电池容量 C 。

7.3.5 联动约束

为使优化结果能够与标准 VRP 结果解析管线无缝衔接，我们建立了时空弧变量向传统 VRP 变量的显式映射：

$$v_j = \sum_{s_1=0}^{P-1} \sum_{e \in \delta_{ST}^+(j, s_1)} x_e, \quad \forall j \in \mathcal{J} \quad (7.8)$$

$$u_j = \sum_{s_2=0}^P \tau_{s_2} \sum_{e \in \delta_{ST}^-(j, s_2)} x_e, \quad \forall j \in \mathcal{J} \quad (7.9)$$

$$y_j = \sum_{s_1=0}^{P-1} \sum_{e \in \delta_{ST}^+(j, s_1)} y^e \cdot x_e, \quad \forall j \in \mathcal{J} \quad (7.10)$$

约束 (7.8) 将访问标志等价于是否存在从 j 出发的时空弧。约束 (7.9) 将到达时间锚定为进入时空节点 (j, s_2) 所对应的物理时间 τ_{s_2} 。约束 (7.10) 将换电量映射为激活出弧上携带的 y^e 值。

7.3.6 变量域

$$x_e \in \{0, 1\}, \forall e \in \mathcal{E}; \quad v_j \in \{0, 1\}, u_j \geq 0, y_j \in \{0, 1, \dots, C\}, \forall j \in \mathcal{J} \quad (7.11)$$

7.4 贪心热启动启发式

为确保 Gurobi 在根节点即获得高质量的初始可行解 (primal bound)，我们采用基于效用/行驶时间比的贪心最近邻构造启发式。从充电柜出发，对当前节点 KNN 邻域内的每个未访问 grid j ，评估其在预计到达时间步下所有可行换电量的最大效用，按效用/行驶时间比排序，选择最优者，并验证返程可行性（若无法在时间 T 内返回充电柜，则逐级递减换电量以腾出返程时间）。该启发式的复杂度为 $O(N \cdot K \cdot |\mathcal{Y}|)$ ，通常在 0.1 秒内完成。生成的物理动作序列被转化为时空弧激活模式，作为 Gurobi MIP Start 注入。由于启发式建立在与 MIP 模型完全相同的 KNN 图和时间离散化规则之上，所构造的路径在 STGraph 中天然可行。

7.5 求解器参数配置

Gurobi 参数的调优充分针对 STGraph 的结构特性：

- **根节点 LP 使用 Barrier 方法。** STGraph 的约束矩阵是一个大规模、稀疏、高度结构化的网络流矩阵，Barrier（内点法）的收敛速度远超单纯形法，通常数十次迭代即可收敛至机器精度。
- **禁用 Crossover。** 将 Barrier 基转换为单纯形可行基（crossover）在网络流矩阵上异常耗时且对后续 B&B 价值有限——直接使用 Barrier 基。
- **完整预求解与适度割平面。** 与 Delta-MCF 模型不同，STGraph 无需 LazyConstraints，因此 Gurobi 可以正常进行完整的代数预求解（变量和约束均被大幅削减）和割平面生成，充分发挥了求解器的全局优化能力。
- **分支优先级。** 访问变量 v_j 被赋予最高分支优先级，因为访问集合一旦确定，换电量 y_j 和到达时间 u_j 即被时空流守恒唯一锁定。

7.6 求解性能概要

STGraph 在 $P = 10$ 配置下以 156 秒求得全局最优解（MIP gap 0.98%），访问 7 个 grid，用尽全部 20 块电池（全部用于更换即将耗尽状态的电池），行驶耗时 0.307h、换电耗时 0.400h，周期总长 0.707h。将 P 提升至 12 后，求解时间仅增至 166 秒（+6.4%），目标值提升至 1.824（+5.4%），访问 grid 数增至 8 个，两种配置均仅探索 1 个 B&B 节点即完成最优性证明，而结果表明，虽然 P 的精度会影响路径规划本身，但无论何种分割方式，目标函数值的差异控制在 5% 左右，且根节点 LP 松弛目标值与最优整数解的偏差均不到 1.0%，体现了网络流矩阵结构的自然紧致性。完整的实验对比、消融分析与方法讨论详见第 8 节。

8 数值实验与分析

8.1 实验设置

数值实验的数据来源取自 2025-11-02 12:00 的全区域快照，覆盖 663 个 H3 六边形 grid（分辨率 8），经 Geo-Fencing 零效用过滤后保留 465 个活跃 grid。充电柜位置取所有活跃 grid 的几何质心。公用参数统一设置为：车速 30 km/h，车载容量 $C = 20$ 块，规划周期 $T = 1.0$ h，单块换电耗时 $c = 0.02$ h，弧段行驶时间裁剪阈值 0.2h，离散换电量 $y \in \{1, \dots, 10\}$ ，求解时限 1200s。时间离散段数 P 设置为 10 和 12 两个水平——前者保持与前序模型开发阶段的可比性，后者基于敏感性分析（第 9 节）中被证实为精度—效率的更优平衡点。

为系统验证提出方案的有效性并诊断各组件的独立贡献，设置 7 组实验，分为三类：

- **提出方案（2 组）：** M1 — STGraph 完整配置（ $P = 10$ ，Geo-Fencing 开启，KNN 稀疏化 $K = 50$ ），作为与前序模型开发阶段可比的性能基准；M1-P12 — STGraph（ $P = 12$ ，其余同 M1），用于建立与敏感性分析（第 9 节）基准配置的直接桥梁。
- **消融实验（2 组）：** M2a — 关闭 Geo-Fencing（保留 KNN，全部 663 个 grid 参与优化），用于量化零效用过滤的贡献；M2b — 关闭 KNN（保留 Geo-Fencing，退化为全连接空间网络），用于量化 KNN 稀疏化的贡献。

- **基准对比 (3 组):** M3 — SOS2-PLA + 全量显式 MTZ 约束, 代表传统分段线性 MIP 范式; M4 — Delta 增量二元编码 + 显式 MTZ, 消去 SOS2 结构开销但保留显式 Big-M; M5 — Delta + MCF 流约束 + 延迟 MTZ 回调 (LazyConstraints), 代表当前最强的非 STGraph 方案。三组基准模型均使用 $P = 10$ 以保证离散精度可比。

8.2 整体性能对比

表 6 汇总了全部 6 组实验的核心指标。

表 6: 全部实验组求解性能与解质量对比 (时限 1200s)

实验组	求解状态	目标值	Gap (%)	耗时 (s)	变量数	约束数	B&B节点	访问grid
M1 (STGraph, $P=10$)	最优	1.730	0.98	156	2,129k	6,980	1	7
M1-P12 (STGraph, $P=12$)	最优	1.824	0.97	166	2,543k	7,927	1	8
M2a (无Geo-Fence)	最优	1.729	0.95	383	3,056k	9,950	1	7
M2b (无KNN)	最优	1.766	0.99	1,598	10,001k	6,980	1	8
M3 (SOS2)	超时	1.854	71.08	1,218	178k	128k	2,614	9
M4 (Delta)	超时	1.477	87.58	1,219	173k	212k	2,875	9
M5 (Delta-MCF)	超时	1.885	N/A	1,216	294k	213k	—	5

所有实验组均在求解时限内找到了可行解。四个 STGraph 系列实验组 (M1、M1-P12、M2a、M2b) 均证得了全局最优, 且均仅需探索 1 个 B&B 节点——其根节点 LP 松弛与整数最优解极为接近, 验证了 STGraph 架构中 LP 紧致性对 P 的取值具有鲁棒性。M1-P12 ($P = 12$) 较 M1 ($P = 10$) 目标值提升 5.4% ($1.730 \rightarrow 1.824$), 变量规模增加 19.4% ($2,129k \rightarrow 2,543k$), 求解时间仅增加 6.4% ($156s \rightarrow 166s$)——以可控的模型膨胀换取了显著的质量增益。 $P = 12$ 还带来了额外的时序一致性改善: M1-P12 的事后时序审计偏差压缩到 1min 以内 (完美对齐), 这得益于更细的时间 grid 使右取整操作的保守松弛从 $\leq 0.1h$ 缩小至 $\leq 0.083h$ 。相比之下, M3 (SOS2) 和 M4 (Delta) 分别在 1200s 后剩余 71.08% 和 87.58% 的 MIP gap, B&B 树已扩展至两千余节点而无收敛迹象。M5 (Delta-MCF) 虽然找到了目标值最高的可行解 (1.885), 但因其依赖 LazyConstraints 机制, Gurobi 报告的对偶界未计入全部延迟约束, 故实际 gap 无法可靠估计 (标记为 N/A); 更关键的是, M5 路由的事后时序审计发现了 4 处严重的时序违规 (详见 8.4 节), 其目标值虽高但并不对应物理可行的调度方案。

8.3 消融实验分析

Geo-Fencing 空间剪枝的效果 (M1 vs. M2a)。关闭 Geo-Fencing 后, 全部 663 个 grid 参与优化 (含 198 个零效用 grid), 模型规模上升约 44% (变量从 213 万增至 306 万, 约束从 6,980 增至 9,950), 求解时间从 156s 增至 383s (+145%)。目标值从 1.730 降至 1.729, 两者几乎完全一致 (差异 $< 0.03\%$), 表明 Geo-Fencing 精准地剔除了对目标函数毫无贡献的零效用 grid, 未造成任何解质量损失。Geo-Fencing 以极低的计算开销 (一次全 grid 效用遍历) 换取了约 30% 的模型规模压缩和近 60% 的求解加速。

KNN 空间稀疏化的效果 (M1 vs. M2b)。关闭 KNN 退化为全连接空间网络后, 变量数从 213 万暴涨至 1,000 万 (+370%), 求解时间从 156s 激增至 1,598s (+924%)。由于全连接网

络提供了更丰富的路由选择，M2b 找到了略优于 M1 的可行解（1.766 vs. 1.730，提升 2.1%），通过访问 8 个而非 7 个 grid 获得了 0.036 的边际效用增益。值得注意的是，M2b 的预求解阶段耗时长达 580s（占总时间的 36%），且 MIP 热启动解因违反联动约束而被求解器拒绝——这揭示了全连接网络不仅增加模型规模，还会降低启发式解的质量。对于实际应用中可能需要的多时段滚动优化或更大规模实例，KNN 稀疏化以微小的质量代价（< 3%）换取了约 90% 的求解时间缩减，是维持可解性的必要条件。

8.4 STGraph 的先进性分析

综合实验结果，STGraph 架构相对于传统 Big-M 范式的优越性体现在四个维度。

1. 唯一证得全局最优的架构家族。M1、M1-P12、M2a、M2b——全部四个 STGraph 变体——均在 1200s 时限内完成了最优性证明，且均仅探索 1 个 B&B 节点。M1-P12（ $P = 12$ ）尤其值得注意：尽管变量规模较 M1（ $P = 10$ ）增加了 19.4%，求解时间仅从 156s 微增至 166s，目标值却提升了 5.4%——通过调节单一离散化参数即获得了实质性的质量增益，且 LP 紧致性完全保持。M3（SOS2-PLA）和 M4（Delta-PLA）虽然模型规模远小于 STGraph（变量数仅为其 6%–8%），但分别因 LP 松弛极弱和 Big-M 约束的结构性缺陷而无法收敛，1200s 后 gap 仍高达 71.08% 和 87.58%。这一结果印证了整数规划领域的一条核心洞见：**模型紧致性比规模更能决定 MIP 求解效率。**

2. LP 松弛的自然紧致性。表 7 汇总了各模型的根节点 LP 松弛与整数最优解的对比。STGraph（M1）的根节点 LP 目标值（1.747）与最优整数解（1.730）的比值仅为 1.010。反观 M3、M4 和 M5：三者的根节点 LP 目标值均约为 3.309，与各自整数解的比值分别为 1.78、2.24 和 1.76。这一系统性差异揭示了 Big-M 约束的深层危害：无论采用 SOS2、Delta 还是 MCF 编码，只要模型中包含 $M(1 - x_{ij})$ 形式的约束，LP 松弛就会在分数 x_{ij} 值上将到达时间变量 u_j 与 u_i 解耦，产生严重高估的目标值上界。STGraph 的网络流结构从根源上消灭了这一机制——时间单调性由 DAG 拓扑保证，而非代数约束强加。

表 7: 各模型根节点 LP 松弛与整数解的紧致性对比

模型	根节点 LP	最优整数解	LP/IP 比值	B&B 节点数
M1 (STGraph)	1.747	1.730	1.01	1
M3 (SOS2)	3.309	1.854	1.78	2,614
M4 (Delta)	3.309	1.477	2.24	2,875
M5 (Delta-MCF)	3.309	1.885	1.76	9*

*M5 因 LazyConstraints 导致 B&B 搜索被结构性阻断，详见下文。

3. 时序一致性的拓扑保证 vs. 延迟回调的根本失效。M5（Delta-MCF）的实验结果为延迟约束回调方案提供了迄今为止最明确的否定性证据。从求解日志来看：(i) M5 在 1200s 内仅探索了 9 个 B&B 节点——LazyConstraints 的启用导致 Gurobi 无法进行有效的割平面生成和预求解，搜索树几乎停滞；(ii) 尽管在 NoRel 启发式阶段仅用 11s 即找到了目标值 1.885 的可行解，但事后时序审计发现了 **4 处严重时序偏差（每处 > 0.05h）**：物理模拟累计时间单调递增（0.056 → 0.248 → 0.320 → 0.371 → 0.462h），而模型联动锚定时间在第二个 grid 处即跌至 0.000h——意味着求解器声称车辆在时刻零“同时”位于充电柜和第二个访问 grid。物理不可行性

表现为时间倒流。

这一现象的机制根源在于：延迟 MTZ 回调仅在当前分支上发现整数解时才注入违规割，无法阻止兄弟分支产生新的违规解，且 LazyConstraints=1 使 Gurobi 无法对注入的割进行全局传播。M5 共注入了 280 个 lazy cuts，仍未能阻止违规——这并非实现细节的瑕疵，而是将硬约束降级为 callback 注入式 lazy cut 这一策略的结构性失败。相比之下，STGraph 将时间单调性编码为有向边的拓扑性质——在 DAG 中，从 (i, s_1) 到 (j, s_2) 的弧天然要求 $s_2 \geq s_1 + 1$ ，时序可行性不再是需要“验证”的约束而是图的定义。M1 的时序审计结果为 0 处偏差，验证了拓扑保证的有效性。

4. 预求解与割平面的充分可用性。STGraph 无 LazyConstraints 依赖，Gurobi 可正常执行完整预求解和割平面生成。M5 因 LazyConstraints=1 导致 Cuts 参数被迫设为 0（割平面与延迟约束相互干扰），预求解亦大幅受限——这一代价并非模型本身所致，而是延迟约束机制的固有代价。两个 Delta 模型（M4 和 M5）共享几乎相同的变量域和效用编码，但 M4（显式 MTZ）在 1200s 内探索了 2,875 个节点，而 M5（Lazy MTZ）仅探索了 9 个——LazyConstraints 对 B&B 搜索的抑制作用甚至超过了显式 Big-M 约束的 LP 松弛松散性。

8.5 数值实验总结

本实验从计算效率、解质量、模型紧致性和时序正确性四个维度系统对比了 7 组实验（5 种 MIP 建模方案，含 STGraph 在 $P = 10$ 和 $P = 12$ 两个离散精度水平下的配置）。核心结论如下：

(1) **STGraph 架构的四个变体均证得全局最优**，且均仅需 1 个 B&B 节点——其根节点 LP 松弛与整数解的比值仅为 1.01（ $P = 10$ ），体现了网络流矩阵结构的天然紧致性。将 P 从 10 提升至 12 后，模型以 19.4% 的变量增长和 6.4% 的求解时间增长换取了 5.4% 的目标值提升，且时序审计偏差从接近零改善至完美为零——这一“免费”的时序保真度增益是 STGraph 框架中 P 作为精度控制参数的直观体现。相比之下，三个传统 Big-M 方案（M3/M4/M5）在 1200s 时限内均无法收敛，gap 高达 71%–88% 或无法可靠估计。

(2) **双层空间稀疏化在解质量与计算效率间实现了优异的平衡。**Geo-Fencing 以零解质量损失换取 30% 的模型压缩和 60% 的求解加速；KNN 稀疏化以 $< 3\%$ 的边际效用代价换取 90% 的求解时间缩减。二者联合使用时（M1），模型在 156s 内即完成最优性证明——适用于多时段滚动优化等对时效性要求高的运营场景。

(3) **延迟约束回调方案（M5）存在结构性的时序不可行问题。**尽管 M5 在 11s 内即找到了高目标值的可行解，但路由的事后审计发现 4 处严重时序偏差——物理累计时间与模型锚定时间完全脱钩，出现到达时间倒流至零的物理矛盾。280 个 lazy cuts 的注入仍未能阻止违规，且 LazyConstraints 的启用导致预求解和割平面生成几乎失效。这一发现传达了一个明确的建模警示：在具有时间依赖目标函数的路径优化问题中，将时序硬约束降级为 callback 注入式的 lazy cut 无法替代拓扑层面的约束内嵌。

(4) **变量规模并非 MIP 复杂度的可靠代理。**STGraph（M1）以 12 倍于 SOS2（M3）的变量规模实现了 8 倍的求解加速，且所有 STGraph 变体均是唯一完成最优性证明的方案家族。模型紧致性——即 LP 松弛与整数包络的贴合程度——比变量或约束的绝对数量更能决定 MIP 的求解难度。

综合以上，时空图重构策略通过将连续时间的复杂依赖关系从代数约束转化为有向无环图的拓扑性质，实现了问题结构的根本性简化。这一方法论对具有时间依赖目标函数的车辆路径问题具有普适性参考价值。

9 敏感性分析

在真实的运营场景下，模型性能对关键参数的依赖程度直接影响调度方案的鲁棒性与可迁移性。对于车载容量、时空离散颗粒度等设计参数，我们期待给出一个最优的配置；而针对车速、换电服务时间等应用场景参数，我们希望揭示其对调度性能的敏感性，以便在实际运营中进行合理的参数选择和风险评估。本节以基准配置（speed=30 km/h, $C_{\max} = 20$, $P = 12$, $c = 0.02\text{h}$ ）为中心，对车速、车载容量、时空离散段数和换电服务时间四个参数进行单因素扫描，并进一步开展 $P \times \text{speed}$ 交叉项联合扫描，以揭示参数间的交互结构。全部实验均在 Gurobi 默认容差下达到 OPTIMAL 终止，求解环境与第 8 节一致。

9.1 单因素敏感性分析

表 8 汇总了四个单因素参数的扫描范围、目标函数变动幅度及核心发现。各参数扫描时其余参数固定于基准值，每次独立求解后记录目标函数值、Time_Gap、换电量和访问grid数。

表 8: 单因素敏感性分析汇总

参数	扫描范围	obj 范围	变动幅度	核心特征
vehicle_speed.kmh	[15, 50] km/h	1.492–1.855	+24.3%	全程触及容量上限；25 km/h 后增长明显放缓
$C_{\max}$	[10, 30] 块	1.228–2.037	+65.9%	持续增长但边际递减； $C_{\max} = 10$ 耗时 1294s
P (intervals)	[6, 20] 段	1.294–1.912	+47.8%	$P = 16$ 最优； $P = 20$ 轻微回落；Time_Gap 单调递减
swap_time.c	[0.02, 0.05]h	1.824–1.182	−35.2%	0.03→0.04 为断崖区（换电量 20→16）

车速。图 2 展示了车速与求解耗时及目标函数的双轴关系。目标函数随车速单调递增但边际递减显著：15→25 km/h 贡献 +18.1% 的目标增益，而 25→50 km/h 仅贡献 +5.3%。所有速度下换电量均触及 $C_{\max} = 20$ 的上限——系统始终运行在“容量饱和”状态，车速的增益全部来自更紧凑的时序安排带来的效用提升，而非换电量的增加。值得注意的是，Time_Gap 并非单调变化：在 20–25 km/h 区间出现局部最优（0.052–0.058h），随后在 35 km/h 以上显著攀升至 0.118h（50 km/h 时约为 7 min），反映了固定 $P = 12$ 离散段下，高速行驶使物理到达时间更难精确对齐到离散时间锚点。求解耗时随车速温和增长（172s→319s），因更长的可触达半径扩大了搜索空间。

车载容量。图 3 以柱状—折线组合图呈现了换电总量与目标函数随 $C_{\max}$ 的变化。与旧有认知不同，目标函数在 $C_{\max} = 20$ 之后并未出现完全饱和，而是呈现出清晰的边际递减格局： $C_{\max}$ 每增加 5 块，目标函数的边际增益依次为 +29.7%（10→15）、+14.5%（15→20）、+9.4%（20→25）和 +2.1%（25→30）。换电量与访问grid数同步增长（从 6 个增至 10 个），表明更大的车载容量允许服务车在一次巡回中覆盖更广的空间范围和更多的需求点。 $C_{\max} = 10$ 的求解耗时高达 1294s——略微超出 1200s 的设定时限但仍收敛至全局最优——反映了紧容量约束下决策树深度暴增的组合优化特征； $C_{\max} \geq 15$ 后求解耗时稳定在 150–241s 区间。这一发现具有




图 2: 车速单因素扫描: 求解耗时与目标函数的双轴对比

明确的运营含义: 在 1h 规划周期下, 容量从 20 扩至 25 仍可带来近 10% 的效用提升, 运营者应基于车辆装载能力与边际效用的成本权衡来决策, 而非简单地接受“容量饱和”的假说。

时空离散段数。图 4 揭示了 P 对求解耗时与 Time_Gap 的双重影响。 P 是单因素中除 $C_{\max}$ 外影响最大的参数 (波动幅度 47.8%)。 $P = 16$ 为全局最优配置 (obj=1.912), 其访问 10 个grid、Time_Gap 仅 0.057h (≈ 3.4 min); $P = 20$ 出现轻微的目标回落 (obj=1.842, 较 $P = 16$ 下降 3.7%), 但 Time_Gap 继续改善至 0.042h——这是离散精度与求解质量之间权衡的体现: 过细的离散将搜索空间碎片化, MIP 在限定时长内更难以充分探索。Time_Gap 随 P 增大单调递减 (0.211 $\rightarrow$ 0.042h), 验证了细粒度离散对时序保真度的系统性改善。 $P = 6$ 的粗离散严重损害模型性能: 仅能访问 5 个grid、换电 19 块 (未用满容量), Time_Gap 高达 0.211h (≈ 12.7 min), 离散误差不可接受。

换电服务时间。图 5 展示了换电时间对求解耗时与目标函数的双轴影响。目标函数随换电时间增加单调递减, 总降幅 35.2%。关键断崖位于 0.03 $\rightarrow$ 0.04h 区间: 单块换电仅增加 0.01h (0.6 min), 换电量却从 20 骤降至 16 块 (-20%)、访问grid数从 7 降至 5——这是时间窗口被压缩后车辆被迫牺牲远端高价值grid的直接表现。进一步增至 0.05h 后换电量降至 14 块, 但降幅明显趋缓 (-12.5%)。与车速不同, 换电时间的负面影响无法通过增加车载容量来弥补——瓶颈在时间窗口的物理约束而非空间容量。Time_Gap 全程保持在低位且无明显趋势 (0.031–0.073h), 表明 STGraph 的时序离散化机制对换电时间参数的变化具有良好的稳健性。

9.2 交叉项分析: $P \times \text{vehicle_speed}$

单因素分析揭示了 P 和 speed 对 Time_Gap 存在方向相反的影响—— P 增大缩小离散误差, 而 speed 增大扩大离散误差。二者对目标函数的影响是否独立? 为量化两者的交互结构, 我们在 $P \in \{8, 12, 16\}$ 和 $\text{speed} \in \{20, 30, 40, 50\}$ 的 3×4 grid上进行联合扫描 (固定 $C_{\max} = 20$, $c = 0.02$ h)。表 9 给出了 12 个组合的目标函数矩阵, 图 6 以四面板视图提供了多维度的可视化诊断。




图 3: 车载容量单因素扫描：换电总量与目标函数的组合对比

表 9: $P \times \text{speed}$ 交叉项目标函数矩阵

	Speed=20	Speed=30	Speed=40	Speed=50
$P = 8$	1.533	1.540	1.541	1.541
$P = 12$	1.583	1.824	1.846	1.855
$P = 16$	1.684	1.912	2.011	2.011

交叉项分析揭示了四个核心发现：

(1) $P = 8$ 构成刚性的“路由天花板”。 $P = 8$ 下，speed 从 20 提升至 50 仅带来 +0.5% 的目标增益（1.533→1.541），速度几乎完全失效。对称地， $P = 8$ 的求解耗时在所有速度下均为最低（78–97s），但这恰恰是“廉价劣解”的典型信号——模型因离散精度过低而快速收敛至一个被结构性压制的局部最优。物理机制清晰：粗离散下时间步跨度 $\Delta = 1/8 = 0.125\text{h}$ （7.5 min），右取整操作将大量本可被利用的行驶时间“吞噬”为离散间隙，无论车速多快都无法转化为额外的访问机会。

(2) P 与 speed 的正向协同仅在 $P \geq 12$ 时被激活。 $P = 12$ 下 speed 20→50 贡献 +17.2% 的增益， $P = 16$ 下同速度跨度的增益达 +19.4%——速度的价值被细粒度离散显著放大。反过来， P 的边际收益亦随速度放大：Speed=20 时 P 从 8 增至 16 仅提升 +9.9%，而 Speed=50 时提升达 +30.5%。这一交互结构意味着， (P, speed) 必须视为一个联合参数对进行标定——单独优化其中任何一个而忽略另一个，都将导致对方维度上的潜在增益被浪费。

(3) Time_Gap 的“离散吸收”效应。三个 P 水平下 Time_Gap 均随速度单调上升，但上升斜率差异悬殊： $P = 8$ 下 Time_Gap 从 0.079h 增至 0.178h（+125%，50 km/h 时误差达 10.7 min）， $P = 12$ 下为 +103%， $P = 16$ 下仅为 +67%（0.043→0.072h，最大误差仅 4.3 min）。物理机制直接明了：高速扩大了相邻离散点间的物理时间跨度，而增加 P 恰好以更高分辨率的离散grid“吸收”了这一效应——这正是 STGraph 框架中 P 作为时序保真度控制参数的核心价




图 4: P 单因素扫描: 求解耗时与 Time_Gap 的双轴对比 ($P = 6, 8, 10, 12, 16, 20$)

值。

(4) 全局最优组合与速度饱和。最优组合为 $P = 16 \times \text{Speed} = 40$ ($\text{obj} = 2.011$), 而 $P = 16 \times \text{Speed} = 50$ 给出完全相同的目标值——在 $P = 16$ 的细离散下, 40 km/h 已足以在 1h 时间窗内触达所有高价值grid, 进一步提升速度不再转化为额外效用, 系统进入了”速度饱和”状态。最劣组合为 $P = 8 \times \text{Speed} = 20$ ($\text{obj} = 1.533$), 极差 31.2%。参数组合选择对模型性能有约三成的影响, 不及单因素 $C_{\max}$ 的波动幅度 (65.9%), 但仍然高度显著。

9.3 参数选择启示

基于单因素与交叉项的敏感性分析, 我们为实际部署场景提供以下参数选择指导:

(1) P 与 speed 须协同标定。 P 的单因素波动幅度 (47.8%) 在四个参数中位居第二, 且交叉项分析确证粗 P 结构性压制速度的增益空间—— $P = 8$ 下速度的价值被压制到仅剩 0.5%, 几近归零。grid分布分散、预期车速较高 (≥ 40 km/h) 的场景须同步提升 P 至 16, 否则速度优势被粗离散”虚耗”; 车速受限的拥堵区域 (≤ 20 km/h) 中 $P = 12$ 已足够, 进一步提升 P 的边际收益不足 10%。运营者应根据服务区域的预期路况, 将 (P, speed) 作为一个耦合参数对联合标定。

(2) $C_{\max}$ 是效用上限的首要决定因素。与单因素分析中其余参数不同, $C_{\max}$ 直接决定车辆在一次巡回中的最大服务能力。在 1h 规划周期下, $C_{\max}$ 从 10 增至 30 贡献了 +65.9% 的目标增益——超过 P 和 speed 的单因素贡献之和。 $C_{\max}$ 每增加 5 块的边际增益呈递减趋势 (29.7% $\rightarrow$ 14.5% $\rightarrow$ 9.4% $\rightarrow$ 2.1%), 运营者应在车辆装载成本与边际效用之间寻找经济最优点。对于预算敏感的场景, $C_{\max} = 20$ 捕获了约 90% 的最大可能效用 (以 $C_{\max} = 30$ 为参照), 是性价比较高的锚点。若规划周期 T 延长, 需重新标定此阈值——更长的时间窗口将释放更多的换电机会, 使容量边际递减曲线整体右移。

(3) 换电服务时间是运营效率的硬瓶颈。 c 从 0.02h 增至 0.05h 导致目标函数下降 35.2%, 且该损失无法通过增大 $C_{\max}$ 或提升车速来补偿——瓶颈在于时间窗口被服务耗时物理性侵蚀,




图 5: 换电服务时间单因素扫描：求解耗时与目标函数的双轴对比

而非空间容量或移动速度不足。0.03→0.04h 区间是风险最高的断崖带。若现场单次换电操作耗时在 2–3 min 区间（0.033–0.05h），运营者应优先考虑：(a) 延长规划周期 T 以容纳等量服务；(b) 部署多服务车协同调度以分摊时间压力；(c) 优化换电流程本身（如预分拣电池、标准化接口）以压缩单次耗时。

(4) **STGraph 对不同参数组合具有稳健的求解性能。** $C_{\max} = 10$ （1294s）因紧容量导致的组合爆炸而略微超出时限，其余所有 26 个扫描组合均在 48–319s 内求得全局最优。Time.Gap 对换电时间的变化不敏感（始终 $< 0.08h$ ），对 P 的调节响应高度可预测（单调递减），对车速的敏感性可通过协同提升 P 来有效控制。这一稳健特性对实际部署具有重要价值：运营参数的现场调整（如因交通状况改变预期车速、因设备升级改变换电耗时）不会导致求解质量出现剧烈波动。

9.4 模型泛化能力验证

前述敏感性分析聚焦于单一时刻快照下的参数响应结构，一个自然的问题是：STGraph 模型在不同时段、不同需求模式下是否仍能保持一致的求解质量？共享电单车系统的需求分布具有显著的时变特征——工作日早高峰（约 08:00）的租还需求可达凌晨（03:00–05:00）的 5–8 倍，需求空间格局亦存在系统性差异。若模型仅在特定时段有效，其实用价值将大打折扣。

为验证模型的时序泛化能力，我们从数据覆盖范围内（2025-10-24 至 2025-11-08）随机选取 20 个独立的小时级时间快照，涵盖午夜至深夜的全天候时段及工作日与周末两类日历条件。每个快照下独立运行 STGraph 完整管线（ $P = 12$, $C_{\max} = 20$, speed=30 km/h, $c = 0.02h$, 时限 1200s），记录求解状态、目标函数、求解耗时及路由特征。




图 6: $P \times \text{vehicle_speed}$ 交叉项敏感性分析: (左上) 目标函数热力图; (右上) 求解耗时热力图; (左下) 不同 P 下速度对目标函数影响的折线对比; (右下) 不同 P 下速度对 Time_Gap 影响的折线对比

9.4.1 整体结果

20 个时间快照中, 19 个成功求得全局最优解 (成功率 95%), 1 个快照 (10/25 21:00) 因该时刻活跃grid数过多导致内存溢出 (OOM), 属数据规模超限而非算法缺陷。表 10 按需求模式分类汇总了核心指标。

9.4.2 昼夜双峰: 需求驱动的效用分化

目标函数呈现鲜明的昼夜双峰结构: 日间均值 1.954, 夜间均值仅 0.427, 二者相差近 5 倍。这一分化并非模型不稳定所致, 恰恰相反——它忠实反映了需求分布的时变特征: 日间 (尤其是 07:00–08:00 早高峰) 需求密度高, 大量grid同时出现即将耗尽电池的车辆, 服务车可在单次巡回中捕获高密度效用; 凌晨时段 (02:00–06:00) 需求近乎停滞, 可服务的换电机机会稀疏且分散, 导致换电总量和单grid平均效用均显著下降。三个凌晨快照 (11/04 03:00、11/06 03:00、10/28 03:00) 的换电量未能用满车载容量 (15–18 块)——并非容量约束松弛, 而是模型中可触达的高效用需求本身已低于车载容量。

值得特别关注的是, 夜间快照的访问grid数反而略高于日间 (9.7 vs. 9.0), 且换电量更低——这揭示了一个符合直觉的运营逻辑: 当单个grid的边际效用较低时, 服务车需要”走得更

表 10: 多时间快照求解结果汇总 (19 个成功求解快照)

指标	全部 ($n = 19$)	日间 ($n = 10$)	夜间 ($n = 9$)
目标函数 obj	1.231 ± 0.842	1.954 ± 0.397	0.427 ± 0.218
求解耗时 (s)	232 ± 44	244 ± 35	219 ± 52
MIPGap (%)	< 1.0 (全部)	< 1.0 (全部)	< 1.0 (全部)
访问grid数	9.3 ± 1.3	9.0 ± 1.1	9.7 ± 1.5
换电总量	19.5 ± 1.3	20.0 ± 0.0	18.9 ± 1.5
makespan (h)	0.785 ± 0.052	0.786 ± 0.053	0.785 ± 0.054

日间: 07:00–22:00 共 10 个快照; 夜间: 00:00–06:00 共 9 个快照。

obj 最优值 2.530 (11/08 07:00, 周日早高峰), 最劣值 0.258 (11/04 03:00, 周三凌晨)。

远、访问更多站点”才能收集到足够的换电机会。模型在不同需求密度下自适应地调整了”深度访问”与”广度覆盖”之间的平衡。

9.4.3 求解稳定性

在所有 19 个成功快照中, 模型的求解性能高度一致:

- **收敛性:** 全部快照在 1200s 时限内达到 OPTIMAL 终止, $\text{MIPGap} < 1\%$ (其中 3 个快照 $\text{MIPGap} = 0.0\%$);
- **求解耗时:** 均值为 232s, 极差仅 139s (168–307s), 变异系数 19%, 表明求解难度受需求分布变化的影响有限;
- **路由结构:** makespan 高度集中 ($0.785 \pm 0.052\text{h}$), 说明模型在不同需求场景下均能有效利用 1h 规划窗口, 既不浪费也不过度紧迫;
- **效用来源:** 19 个快照中, 14 个的全部效用来自”即将耗尽”电池, 5 个快照含少量低电量电池换电 (低电量效用占比均 $< 45\%$), 正常电池换电在所有快照中均未发生——这与第 8 节基准实验的效用结构高度一致, 验证了优先换电逻辑 (先低电量后即将耗尽) 在不同需求场景下的稳定运作。

综合以上, STGraph 模型在 19 个跨越不同时段、不同日历类型的独立时间快照上表现出一致且可靠的求解性能。目标函数的绝对水平随需求密度的自然波动而变化, 但求解收敛性、路由效率与效用结构的稳定性共同构成了模型泛化能力的实证支撑。

10 结论与未来工作

10.1 研究总结

共享单车电池换电调度问题的核心困难在于: 随机库存动力学的连续时间特性 (由 ODE 系统刻画) 与传统组合优化的离散决策范式 (由 MIP 模型刻画) 之间存在结构性鸿沟。本文通过三个层面的贡献弥合了这一鸿沟。

建模层面：我们建立了三状态电池库存的流体ODE模型，并利用其结构性特征——净服务价值积分退化为质量加权库存的边界求值——导出了常数时间复杂度的闭式效用函数 $U_j(u_j, y_j)$ 。该函数将随机排队动力学的复杂轨迹压缩为代数求值原语，充当了连续时间随机建模与离散组合优化之间的数学接口。

算法层面：我们提出了STGraph（时空图网络流）MIP重构方法。其核心思想是将时间从约束的右侧提升为图的显式维度——在DAG拓扑中，时间单调性不再是需要Big-M项保证的代数约束，而是有向边天然蕴含的图性质。这一重构从根本上消灭了所有Big-M约束，使LP松弛与整数包络实现了自然紧致性（根节点LP/IP比值仅1.01），且所有STGraph变体均仅需探索1个B&B节点即完成最优性证明。

实证层面：在真实运营数据的7组受控实验和26组敏感性扫描中：(1) STGraph ($P = 10$) 以156秒证得全局最优（gap 0.98%），而三种传统Big-M方案在1200秒后gap仍高达71%–88%；(2) 延迟MTZ回调方案（M5）暴露了结构性的时序不可行问题——280个lazy cuts未能阻止4处严重时序偏差——为“将硬约束降级为callback注入式lazy cut”策略提供了迄今最明确的否定性证据；(3) Geo-Fencing + KNN双层空间稀疏化以< 3%的边际效用代价换取了约90%的求解时间缩减；(4) 在19个跨越全天候时段和不同日历类型的独立测试快照中，模型求解成功率达95%（19/20），验证了方法的时序泛化能力。

从更广泛的方法论视角审视，STGraph的核心贡献在于一种**可迁移的建模策略**：将连续时间的复杂依赖关系从代数约束转化为有向无环图的拓扑性质。这一策略对具有时间依赖目标函数的车辆路径问题变体——包括定向越野问题（OP）、收益路径问题（PTP）和更一般的时效性服务调度问题——具有普适性的参考价值。模型紧致性比变量规模更能决定MIP求解效率这一实证发现，亦为整数规划建模实践提供了具体而有力的方法论启示。

10.2 局限性与未来工作

本文的工作可在以下方向上进一步拓展。

多车辆协同调度。当前模型限定为单车辆单次巡游，实际运营中通常需要多辆服务车协同覆盖更大的区域。STGraph框架在引入车辆维度索引后，变量规模将乘以车辆数，LP紧致性是否能够保持是一个开放问题。可能的求解策略包括：(1) 先通过聚类将grid划分为服务子区，再在各子区内独立求解单车辆STGraph；(2) 引入列生成（column generation）或Benders分解来处理车辆对称性。

端到端决策驱动预测。当前Predict-then-Optimize管线中，上游Hurdle模型以统计精度（MAE）为目标独立训练，未感知下游STGraph的决策结构。自然的延伸方向是采用Smart “Predict, then Optimize”（SPO）框架 [9]或决策聚焦学习（decision-focused learning）[30]，使预测器的训练损失直接面向STGraph的优化结果。这一方向的挑战在于：STGraph的MIP求解过程不可微，需借助替代损失（surrogate loss）或黑箱优化技术桥接。

流体近似的理论误差界与实证验证。本文基于三个核心假设（Poisson到达/离开、随机用户行为、流体近似）建立了ODE动力学，但未对流体近似在有限grid规模下的系统误差进行理论分析或仿真验证。Gast [12]给出了平均场期望值近似的 $O(1/N)$ 误差界——未来的工作可沿此方向：(1) 推导本文三状态模型下效用估计的有限样本误差界；(2) 构建离散事件仿真（DES）验证ODE解析轨迹与Monte Carlo仿真轨迹的一致性，为流体近似在本问题上的适用性提供实证

支撑。

在线滚动时域部署。当前模型假设在每个规划周期 T 开始时一次性确定全部路由计划。更贴近真实运营的是滚动时域 (receding horizon) 在线实现：每小时用最新观测数据更新各grid的电池库存初始条件和Hurdle预测值，重求解STGraph并仅执行当前决策，下一周期再滚动优化。在线部署对求解时间的稳定性提出了更高要求——本文20个快照的求解耗时变异系数为19% (均处于168-307s范围内)，表明STGraph已初步具备在线部署的实时性条件，但更大规模实例的求解时间保障仍需系统评估。

电池退化与全生命周期成本建模。当前目标函数以最大化服务质量效用为唯一优化方向。实际运营中，电池充放电循环的退化成本 (battery degradation cost)、换电操作的人工成本差异以及不同服务时段的人力定价，共同构成了运营决策的经济约束。将本文的单目标优化框架扩展为多目标优化 (如Pareto前沿：服务质量效用 vs. 全生命周期运营成本)，是将方法论从学术研究推向工业部署的关键一步。

参考文献

- [1] Rusul L. Abduljabbar, Sohani Liyanage, and Hussein Dia. The role of micro-mobility in shaping sustainable cities: A systematic literature review. *Transportation Research Part D: Transport and Environment*, 92:102734, 2021.
- [2] Furkan Ahmad, Mohammad Saad Alam, Ibrahim Saad Alsaïdan, and Samir M. Shariff. Battery swapping station for electric vehicles: Opportunities and challenges. *IET Smart Grid*, 3(3):280–286, 2020.
- [3] Deniz Akturk, Ozan Candogan, and Varun Gupta. Managing resources for shared micromobility: Approximate optimality in large-scale systems. *Management Science*, 71(7):5676–5695, 2024.
- [4] Michel Benaïm and Jean-Yves Le Boudec. A class of mean field interaction models for computer and communication systems. *Performance Evaluation*, 65(11–12):823–838, 2008.
- [5] Yoshua Bengio, Andrea Lodi, and Antoine Prouvost. Machine learning for combinatorial optimization: A methodological tour d’horizon. *European Journal of Operational Research*, 290(2):405–421, 2021.
- [6] Anton Braverman, J. G. Dai, Xin Liu, and Lei Ying. Empty-car routing in ridesharing systems. *Operations Research*, 67(5):1437–1452, 2019.
- [7] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [8] Martin Desrochers and Gilbert Laporte. Improvements and extensions to the Miller-Tucker-Zemlin subtour elimination constraints. *Operations Research Letters*, 10(1):27–36, 1991.
- [9] Adam N. Elmachtoub and Paul Grigas. Smart ”predict, then optimize”. *Management Science*, 68(1):9–26, 2022.
- [10] Thomas Franke and Josef F. Krems. Understanding charging behaviour of electric vehicle users. *Transportation Research Part F: Traffic Psychology and Behaviour*, 21:75–89, 2013.
- [11] Christine Fricker and Nicolas Gast. Incentives and redistribution in homogeneous bike-sharing systems with stations of finite capacity. *EURO Journal on Transportation and Logistics*, 5(3):261–291, 2016.
- [12] Nicolas Gast. Expected values estimated via mean-field approximation are $1/N$ -accurate. *Proceedings of the ACM on Measurement and Analysis of Computing Systems*, 1(1):1–26, 2017.
- [13] GM Insights. Bike sharing market size & share, growth forecasts 2025–2034. Industry report, Global Market Insights, 2025. Report ID: GMI7762.

- [14] Aldy Gunawan, Hoong Chuin Lau, and Pieter Vansteenwegen. Orienteering problem: A survey of recent variants, solution approaches and applications. *European Journal of Operational Research*, 255(2):315–332, 2016.
- [15] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [16] Yaguang Li, Richard Rose, and Eitan Elnekave. Diffusion convolutional recurrent neural network: Data-driven traffic forecasting. In *International Conference on Learning Representations*, 2018.
- [17] Vera Lucas and António R. Andrade. Predicting hourly origin–destination demand in bike sharing systems using hurdle models: Lisbon case study. *Case Studies on Transport Policy*, 9(4):1836–1848, 2021.
- [18] Monirehalsadat Mahmoudi and Xuesong Zhou. Finding optimal solutions for vehicle routing problem with pickup and delivery services with time windows: A dynamic programming approach based on state–space–time network representations. *Transportation Research Part B: Methodological*, 89:19–42, 2016.
- [19] John Mullahy. Specification and testing of some modified count data models. *Journal of Econometrics*, 33(3):341–365, 1986.
- [20] National Association of City Transportation Officials. Shared micromobility in the U.S. and Canada: 2023. Technical report, NACTO, 2024. Available at: <https://nacto.org/publication/shared-micromobility-in-the-us-and-canada-2023/>.
- [21] Eoin O’Mahony and David B. Shmoys. Data analysis and optimization for (Citi)Bike sharing. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 29, pages 687–694, 2015.
- [22] Temel Öncan, İ. Kuban Altinel, and Gilbert Laporte. A comparative analysis of several asymmetric traveling salesman problem formulations. *Computers & Operations Research*, 36(3):637–654, 2009.
- [23] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: Unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, volume 31, 2018.
- [24] Tami Raviv, Michal Tzur, and Itai A. Forma. Static repositioning in a bike-sharing system: Models and solution approaches. *EURO Journal on Transportation and Logistics*, 2(3):187–229, 2013.

- [25] Jasper Schuijbroek, Robert C. Hampshire, and Willem-Jan Van Hoes. Inventory routing and pricing in bike-sharing systems. *European Journal of Operational Research*, 258(3):971–985, 2017.
- [26] Susan Shaheen, Nelson Chan, Apaar Bansal, and Adam Cohen. Shared mobility: A sustainability & technologies workshop: Definitions, industry developments, and early understanding. Technical report, Transportation Sustainability Research Center, University of California, Berkeley, 2015. Available at: <https://escholarship.org/uc/item/2f61q30s>.
- [27] John F. Shortle, James M. Thompson, Donald Gross, and Carl M. Harris. *Fundamentals of Queueing Theory*. John Wiley & Sons, 5th edition, 2018.
- [28] Pieter Vansteenwegen, Wouter Souffriau, and Dirk Van Oudheusden. The orienteering problem: A survey. *European Journal of Operational Research*, 209(1):1–10, 2011.
- [29] Ariel Waserhole and Vincent Jost. Pricing in vehicle sharing systems: Optimization in queuing networks with product forms. *EURO Journal on Transportation and Logistics*, 5(3):293–320, 2016.
- [30] Bryan Wilder, Bistra Dilkina, and Milind Tambe. Melding the data-decisions pipeline: Decision-focused learning for combinatorial optimization. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 33, pages 1658–1665, 2019.
- [31] Laurence A. Wolsey. *Integer Programming*. John Wiley & Sons, 1998.
- [32] Bing Yu, Haoteng Yin, and Zhanxing Zhu. Spatio-temporal graph convolutional networks: A deep learning framework for traffic forecasting. In *Proceedings of the 27th International Joint Conference on Artificial Intelligence*, pages 3634–3640, 2018.
- [33] Yaoming Zhou, Zeyu Lin, Rui Guan, and Jiah-Bing Sheu. Dynamic battery swapping and rebalancing strategies for e-bike sharing systems. *Transportation Research Part B: Methodological*, 177:102820, 2023.